Taller resuelto de aprendizaje profundo
Informe de ejecución

Sergio Santiago Duarte Rojas, código 20261595002
Inteligencia Computacional Aplicada, docente Cesar Andrey Perdomo Charry
Universidad Distrital Francisco José de Caldas, 10 de octubre de 2026

1. Ejecución

Se ejecutó completo el cuaderno `Taller - DeepLearning PYHTON.ipynb` con PyTorch 2.12 sobre una GPU NVIDIA, semilla 42. MNIST se descargó sin recurrir al conjunto de respaldo y quedó partido en 55 000 imágenes de entrenamiento, 5 000 de validación y 10 000 de prueba, normalizadas con la media (0.1307) y la desviación (0.3081) del entrenamiento. Las clases están casi balanceadas, entre 4 946 y 6 188 imágenes. Todos los puntos de control dieron `[OK]`. La Tabla 1 resume los resultados.

Tabla 1: Resultados tras 3 épocas con Adam y tasa 10^{-3}, exactitud en porcentaje

Modelo	Parámetros	Entrenamiento	Validación	Prueba
MLP 784-128-10	101770	97.49	97.02	–
CNN de dos bloques	12810	98.09	98.64	98.70

2. Análisis

MLP frente a CNN. La CNN supera al MLP en 1.6 puntos de validación con ocho veces menos parámetros. La convolución reutiliza los mismos nueve pesos en toda la imagen y aprovecha que los píxeles vecinos están relacionados, algo que el MLP pierde al aplanar la imagen en 784 valores. Las cifras de ambos modelos quedan dentro de los rangos orientativos del cuaderno (96 a 98 % y 98.5 a 99.2 %).

Curvas de aprendizaje. En la CNN la exactitud de validación queda por encima de la de entrenamiento en las tres épocas (Figura 1). No es un error. Durante el entrenamiento el *dropout* apaga el 25 % de las características y en la evaluación no, así que la red se mide en condiciones más fáciles. El MLP, sin *dropout*, ya muestra en la tercera época una pequeña brecha a favor del entrenamiento (97.49 frente a 97.02 %), el primer indicio de sobreajuste.

Errores en prueba. La CNN falla 130 de las 10 000 imágenes de prueba, con pérdida 0.0373. Los pares más confundidos son 4 tomado por 9 (11 veces), 7 por 2 (8) y 2 por 7 (7), como muestra la Figura 2. Son dígitos que difieren en un solo trazo, un 4 con la parte superior cerrada se parece a un 9 y un 7 con trazo curvo o barra inferior se parece a un 2. Los diez primeros errores incluyen además dígitos que una persona también dudaría en clasificar.

Tasa de aprendizaje. La Tabla 2 confirma la predicción del cuaderno. Con 10^{-1} la red diverge y queda en el 10 % de exactitud, el azar entre diez clases, con una pérdida de 2.30 que es justo $\ln 10$, es decir que asigna la misma probabilidad a todas las clases. Con 10^{-5} la pérdida baja de 1.91 a 1.18 entre las dos épocas, así que la red sí aprende, pero demasiado despacio para dos épocas. Con 10^{-3}, el valor habitual para Adam, alcanza el 98.0 %.

Modelo guardado. Los pesos se guardaron en `cnn_digitos.pt` y el modelo recargado dio la misma exactitud de prueba.

Reproducibilidad. En GPU algunas operaciones no son deterministas, así que la CNN cambia en la segunda o tercera cifra decimal entre ejecuciones aun con la misma semilla. En una ejecución

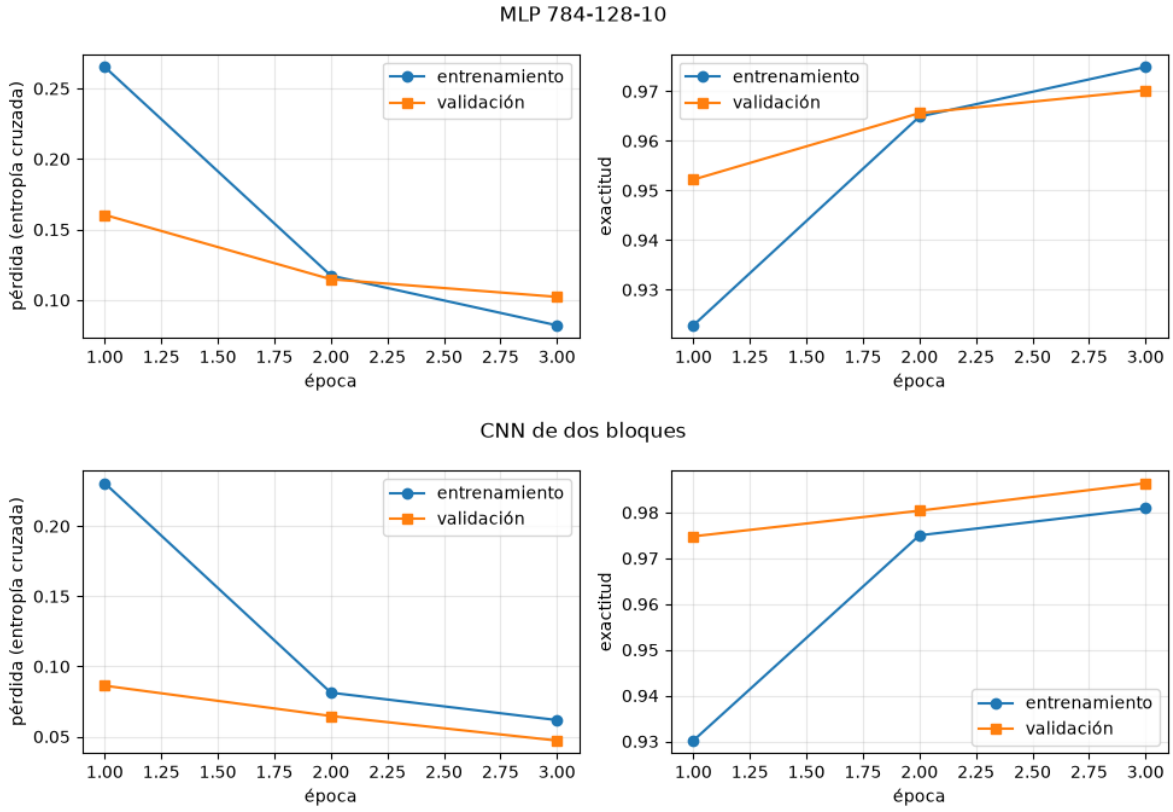


Figura 1: Pérdida y exactitud por época del MLP (arriba) y de la CNN (abajo)

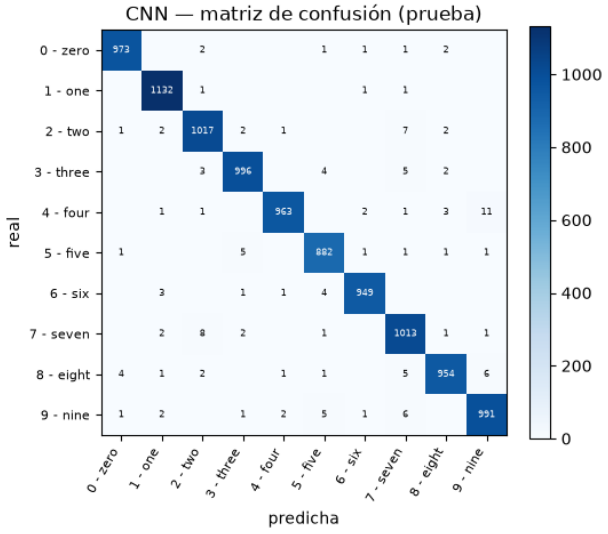


Figura 2: Matriz de confusión de la CNN sobre las 10 000 imágenes de prueba

previa la exactitud de prueba fue 98.62 %. El MLP dio cifras idénticas.

Tabla 2: CNN tras 2 épocas con tres tasas de aprendizaje

Tasa	**Exact. valid. (%)**	**Pérdida valid.**
1×10^{-1}	10.42	2.3045
1×10^{-3}	98.02	0.0586
1×10^{-5}	81.22	1.1829