Actividad 3. Taller resuelto
Reconocimiento de dígitos manuscritos con redes profundas

Informe de ejecución

Asignatura: Inteligencia Computacional Aplicada
Docente: Cesar Andrey Perdomo Charry
Estudiante: Sergio Santiago Duarte Rojas
Código: 20261595002

Fecha: 10 de octubre de 2026

Universidad Distrital Francisco José de Caldas

Índice

1. Introducción **2**

2. Marco teórico (resumen) **2**
2.1. De vectores a imágenes 2
2.2. Pérdida y optimizador 2

3. Metodología **2**
3.1. Datos y particiones 2
3.2. Arquitecturas 3
3.3. Entrenamiento y evaluación 4

4. Resultados **4**
4.1. Curvas de aprendizaje 4
4.2. Evaluación en prueba 5
4.3. Tasa de aprendizaje 5
4.4. Modelo guardado 6

5. Análisis **7**

6. Conclusiones **7**

7. Referencias **8**

1. Introducción

El Taller 2 cerró con un perceptrón multicapa entrenado por retropropagación sobre vectores de pocas entradas. Este taller lleva la misma idea a imágenes. El cuaderno del docente entrena dos redes sobre MNIST, 70 000 dígitos manuscritos de 28 por 28 píxeles, primero un perceptrón multicapa que trata la imagen como un vector de 784 números y después una red convolucional que la trata como una imagen. El objetivo del informe es documentar la ejecución, confirmar los puntos de control y explicar lo que muestran las curvas, la matriz de confusión y el experimento con la tasa de aprendizaje.

El cuaderno se ejecutó completo y sin modificaciones, con PyTorch 2.12 sobre una GPU NVIDIA y semilla 42. MNIST se descargó con torchvision, sin recurrir al conjunto de respaldo que el cuaderno trae para cuando no hay conexión. Los siete puntos de control dieron `[OK]`.

2. Marco teórico (resumen)

2.1 De vectores a imágenes

El MLP del Taller 2 recibe un vector y lo pasa por capas densas, en las que cada neurona se conecta con todas las entradas. Aplicado a una imagen, eso obliga a aplanarla, con lo que se pierde la noción de vecindad entre píxeles y el número de pesos crece con el tamaño de la imagen. Una capa convolucional desliza un filtro pequeño, aquí de 3 por 3, por toda la imagen y calcula en cada posición una suma ponderada con los mismos pesos. Un filtro aprende entonces un rasgo local, un borde o un trazo, y lo detecta en cualquier posición. Una capa con c_{in} canales de entrada, c_{out} filtros y tamaño k tiene $c_{out}(c_{in}k^2 + 1)$ parámetros, sin importar el tamaño de la imagen. El *max pooling* toma el máximo de cada ventana de 2 por 2 y reduce la imagen a la mitad por lado, lo que da tolerancia a desplazamientos pequeños y abarata las capas siguientes.

2.2 Pérdida y optimizador

Con diez clases la salida de la red son diez *logits* z_k. La función softmax los convierte en probabilidades, $p_k = e^{z_k} / \sum_j e^{z_j}$, y la pérdida es la entropía cruzada $L = -\ln p_y$, donde y es la clase correcta. Es la misma cadena de retropropagación del Taller 2 con otra función de activación en la salida y otra medida de error, y tiene la propiedad de que su valor para una red que reparte la probabilidad por igual entre diez clases es $\ln 10 = 2.303$, una referencia útil para leer las tablas. Adam es un descenso de gradiente que adapta el paso de cada peso según el historial de sus gradientes, con lo que una misma tasa de aprendizaje sirve para pesos de escalas muy distintas. El *dropout* apaga al azar una fracción de las activaciones en cada paso de entrenamiento y se desactiva al evaluar, lo que obliga a la red a no depender de unas pocas características.

3. Metodología

3.1 Datos y particiones

MNIST trae 60 000 imágenes de entrenamiento y 10 000 de prueba. El cuaderno aparta 5 000 imágenes del entrenamiento como validación, deja 55 000 para entrenar y reserva la prueba para una sola evaluación final. Los píxeles se llevan de 0 a 255 al rango 0 a 1 y después se normalizan con la media (0.1307) y la desviación (0.3081) calculadas solo sobre el entrenamiento. Las clases están casi balanceadas, entre 4 946 y 6 188 imágenes por dígito. La Figura 1 muestra las primeras dieciséis.

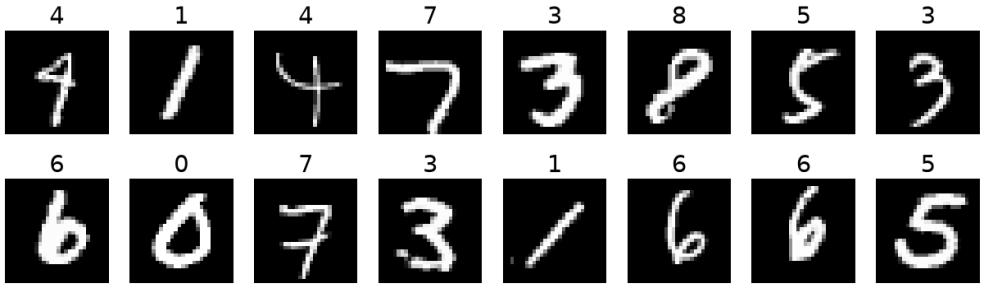


Figura 1: Primeras dieciséis imágenes de entrenamiento con su etiqueta

3.2 Arquitecturas

La Tabla 1 y la Figura 2 describen las dos redes. El MLP aplana la imagen y tiene una capa oculta de 128 neuronas con ReLU, 101 770 parámetros. La CNN tiene dos bloques de convolución 3 por 3 seguida de ReLU y *max pooling*, un *dropout* de 0.25 y una capa lineal, 12 810 parámetros, 7.9 veces menos que el MLP. Ambas devuelven diez *logits* y la softmax va dentro de la pérdida.

Tabla 1: Capas de las dos redes. En la CNN la salida no usa relleno, así que cada convolución quita dos píxeles por lado

Red	Capa	Parámetros
MLP	Aplanar, 784	0
	Lineal 784 a 128 con ReLU	100 480
	Lineal 128 a 10	1 290
CNN	Convolución 3 por 3, 16 filtros, ReLU, salida 16 por 26 por 26	160
	Max pooling 2 por 2, salida 16 por 13 por 13	0
	Convolución 3 por 3, 32 filtros, ReLU, salida 32 por 11 por 11	4 640
	Max pooling 2 por 2, salida 32 por 5 por 5	0
	Aplanar, 800, y dropout 0.25	0
	Lineal 800 a 10	8 010

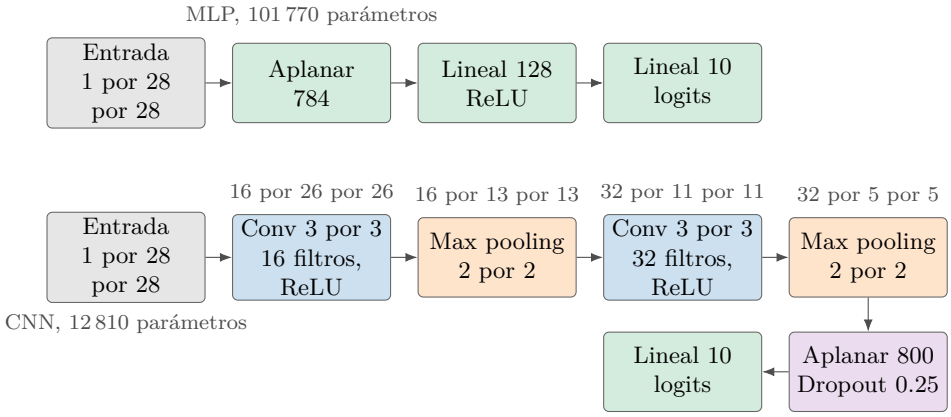


Figura 2: Las dos redes del cuaderno. Encima de cada bloque de la CNN va el tamaño de su salida, canales por alto por ancho

3.3 Entrenamiento y evaluación

Las dos redes se entrenan 3 épocas con Adam, tasa 10^{-3}, lotes de 64 imágenes en orden aleatorio y entropía cruzada. Al final de cada época se mide la pérdida y la exactitud sobre entrenamiento y validación. La prueba se usa una sola vez con la CNN. Después se repite el entrenamiento de la CNN durante 2 épocas con tasas de 10^{-1}, 10^{-3} y 10^{-5}, y por último se guardan los pesos en disco y se recargan para comprobar que la exactitud se conserva.

4. Resultados

4.1 Curvas de aprendizaje

La Tabla 2 y la Figura 3 recogen las tres épocas de cada red. La CNN termina con 98.64 por ciento de validación frente a 97.02 del MLP, 1.6 puntos más, y su pérdida de validación es la mitad. Las dos cifras quedan dentro de los rangos orientativos del cuaderno, 96 a 98 por ciento para el MLP y 98.5 a 99.2 para la CNN.

Tabla 2: Pérdida y exactitud por época. La exactitud está en porcentaje

		Entrenamiento		Validación	
Red	**Época**	**Pérdida**	**Exactitud**	**Pérdida**	**Exactitud**
MLP	1	0.2652	92.28	0.1604	95.22
	2	0.1174	96.49	0.1148	96.56
	3	0.0821	97.49	0.1023	97.02
CNN	1	0.2305	93.01	0.0864	97.48
	2	0.0813	97.51	0.0645	98.00
	3	0.0620	98.07	0.0482	98.64

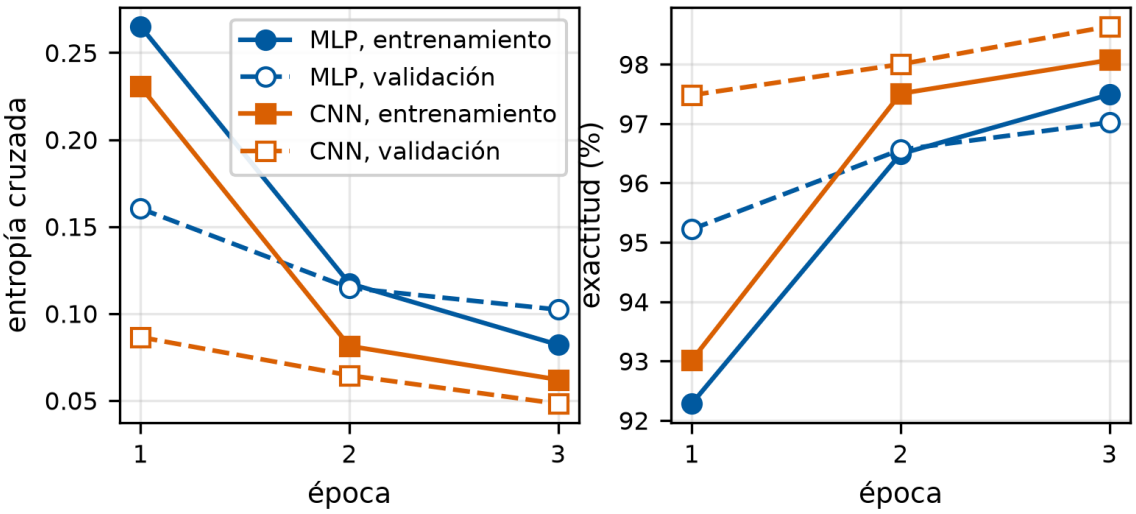


Figura 3: Pérdida y exactitud por época de las dos redes. Línea continua entrenamiento, discontinua validación

4.2 Evaluación en prueba

La CNN acierta 98.65 por ciento de las 10 000 imágenes de prueba, 135 errores, con pérdida 0.0381. La Figura 4 muestra la matriz de confusión y la Tabla 3 el acierto por clase. Los pares más confundidos son 4 tomado por 9 (13 veces), 2 por 7 (8) y 7 por 2 (8). La clase con más acierto es el 1 (99.7 por ciento) y la de menos el 8 (97.9). La Figura 5 muestra los diez primeros errores.

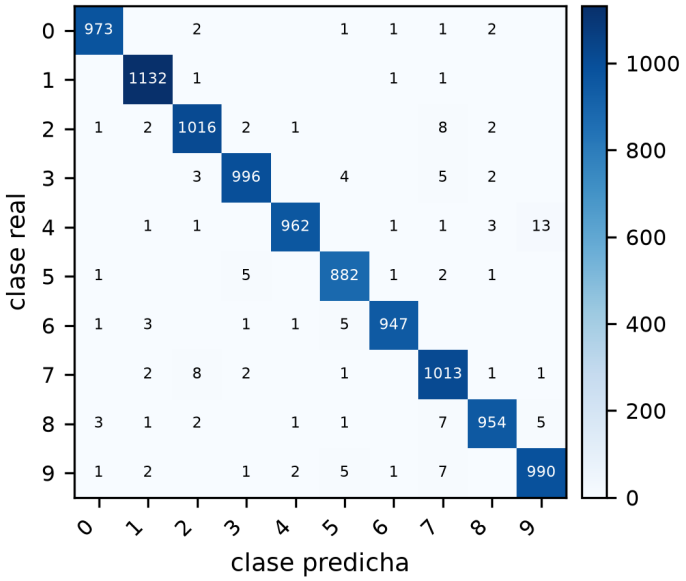


Figura 4: Matriz de confusión de la CNN sobre las 10 000 imágenes de prueba

Tabla 3: Acierto por clase en prueba. El acierto es la fracción de imágenes de la clase bien clasificadas y la precisión la fracción de predicciones de esa clase que eran correctas

Dígito	Imágenes	Aciertos	Acierto (%)	Precisión (%)
0	980	973	99.3	99.3
1	1135	1132	99.7	99.0
2	1032	1016	98.4	98.4
3	1010	996	98.6	98.9
4	982	962	98.0	99.5
5	892	882	98.9	98.1
6	958	947	98.9	99.5
7	1028	1013	98.5	96.9
8	974	954	97.9	98.9
9	1009	990	98.1	98.1

4.3 Tasa de aprendizaje

La Tabla 4 resume el experimento de 2 épocas. Con 10^{-1} la red queda en 10.42 por ciento, el azar entre diez clases, y su pérdida de 2.3045 coincide con $\ln 10$. Con 10^{-5} llega a 81.22 por ciento con una pérdida todavía alta. Con 10^{-3} alcanza 98.10 por ciento.



Figura 5: Los diez primeros errores de la CNN en prueba

Tabla 4: CNN tras 2 épocas con tres tasas de aprendizaje

Tasa	Exactitud de validación (%)	Pérdida de validación
1×10^{-1}	10.42	2.3045
1×10^{-3}	98.10	0.0580
1×10^{-5}	81.22	1.1829

4.4 Modelo guardado

Los pesos de la CNN se guardaron en `cnn_digitos.pt`, se cargaron en una red nueva y la exactitud de prueba fue la misma, de modo que el modelo se puede reutilizar sin entrenarlo otra vez.

5. Análisis

Por qué gana la CNN con menos parámetros. El MLP gasta 100 480 de sus 101 770 parámetros en conectar cada píxel con cada neurona oculta, y cada uno de esos pesos solo sirve para una posición de la imagen. La CNN tiene 160 parámetros en su primera capa porque sus 16 filtros se reutilizan en las 676 posiciones de la imagen, y el *pooling* hace que un trazo desplazado un píxel active casi lo mismo. Con 7.9 veces menos parámetros mejora la validación en 1.6 puntos y reduce la pérdida a la mitad.

Qué dicen las curvas. En la CNN la validación va por encima del entrenamiento en las tres épocas. No es un error de medición. Durante el entrenamiento el *dropout* apaga el 25 por ciento de las 800 características que entran a la capa lineal, y en la evaluación trabaja con todas, así que la red se mide en condiciones más fáciles de las que entrena. El MLP no tiene *dropout* y en la tercera época su entrenamiento ya supera a la validación por medio punto, el primer indicio del sobreajuste que el Taller 2 mostró en Breast Cancer. Tres épocas son pocas para que crezca, pero la dirección es la misma.

Qué dígitos se confunden. Los tres pares más frecuentes son 4 con 9 y 2 con 7 en los dos sentidos. Son dígitos que difieren en un solo trazo, un 4 con la parte superior cerrada se convierte en un 9 y un 7 con el trazo horizontal curvo se parece a un 2. Los errores de la Figura 5 incluyen varios dígitos que una persona también dudaría en clasificar. Que el error se concentre en pares concretos y no se reparta por toda la matriz indica que la red aprendió la forma de cada dígito y falla donde la forma es ambigua.

Qué muestra la tasa de aprendizaje. Con 10^{-1} Adam da pasos tan grandes que la red nunca baja de la pérdida inicial, y su valor de $\ln 10$ dice que termina asignando la misma probabilidad a las diez clases. Con 10^{-5} la pérdida sí baja época a época, así que la red aprende, pero necesitaría muchas más épocas. El valor intermedio de 10^{-3} repite la lección del Taller 2 con la tasa del MLP, demasiado grande oscila o diverge y demasiado pequeña no llega a tiempo.

6. Conclusiones

La red convolucional del cuaderno alcanza 98.65 por ciento en prueba con 12 810 parámetros, y supera al MLP de 101 770 parámetros en 1.6 puntos de validación, porque reutiliza cada filtro en toda la imagen y tolera desplazamientos pequeños.

Las curvas de la CNN con validación por encima del entrenamiento se explican por el *dropout* y no por un problema del entrenamiento, y las del MLP sin *dropout* ya insinúan sobreajuste en la tercera época.

Los 135 errores de prueba se concentran en los pares 4 y 9 y 2 y 7, dígitos que difieren en un trazo, con un acierto por clase entre 97.9 y 99.7 por ciento.

La tasa de aprendizaje decide entre no aprender, aprender despacio y aprender bien. Con Adam el valor de 10^{-3} es el que funciona y 10^{-1} deja la red en el azar.

Todos los puntos de control se cumplieron y el modelo guardado reproduce la exactitud de prueba al recargarse. En GPU algunas operaciones no son deterministas, así que la CNN cambia en la segunda cifra decimal entre ejecuciones con la misma semilla, mientras que el MLP repite sus cifras.

7. Referencias

- LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278–2324.
- Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. *International Conference on Learning Representations*.
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15, 1929–1958.
- Deng, L. (2012). The MNIST database of handwritten digit images for machine learning research. *IEEE Signal Processing Magazine*, 29(6), 141–142.
- Paszke, A. et al. (2019). PyTorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems*, 32.