

Bank Marketing

Preparación del dataset paso a paso para la herramienta de clasificación

Sergio Duarte

Inteligencia Computacional. Maestría en Ciencias de la Información y las Comunicaciones

Universidad Distrital Francisco José de Caldas


El dataset y el plan

UCI Machine Learning Repository, Bank Marketing (Moro, Cortez y Rita, 2014)

- Campañas telefónicas de un banco portugués entre 2008 y 2010. Objetivo, predecir si el cliente suscribe un depósito a plazo
- 45 211 registros, 16 atributos de entrada y la clase y
- Sin valores faltantes explícitos, pero job, education, contact y poutcome usan la etiqueta unknown
- Clase muy desbalanceada, 39 922 no frente a 5 289 sí (11.7 % de positivos)
- Cuatro versiones del dato, cada una probada en Classification Learner con validación cruzada de 5 particiones
 - T0 crudo, tal como viene
 - T1 arreglo de columnas, filas, faltantes y atípicos
 - T2 codificación y estandarización
 - T3 balanceo, por submuestreo (T3_1) y por sobremuestreo (T3_2)

T0. Numéricas










Histogramas de las siete variables numéricas y de la clase



- age es la única con una distribución aproximadamente simétrica
- balance, campaign y previous presentan colas muy pronunciadas, con valores hasta 102 127, 63 y 275
- pdays es casi toda -1 (82 % nunca contactados)
- duration se concentra en llamadas cortas
- y desbalanceada, 7.5 no por cada sí

T0. Categóricas y valores unknown

El dataset no trae faltantes, pero unknown cumple ese papel



Variable	unknown	Decisión
job	288 (0.6 %)	se eliminan las filas
education	1 857 (4.1 %)	se imputa con la moda del oficio
contact	13 020 (28.8 %)	se conserva como categoría
poutcome	36 959 (81.7 %)	coincide con nunca contactado

- month muy concentrado en mayo
- default casi constante, 1.8 % en mora

T1. Arreglo de columnas


Menos columnas y con significado, con intervención mínima sobre el dato

Columna	Tratamiento	Por qué
duration	se elimina	solo se conoce al terminar la llamada, es fuga de información hacia la clase
day y month	se unen en dia_anio (1 a 365)	una sola columna numérica en vez de una numérica y una categórica de 12 niveles
education	ordinal 1, 2, 3	los niveles tienen orden natural, no hace falta one hot
job unknown	se eliminan 288 filas	no hay con qué imputar y son el 0.6 %
pdays	dos campos, ver siguiente lámina	el -1 es un código de ausencia, no una cantidad de días
age, balance, campaign	atípicos recortados al borde de 1.5 IQR	480, 4 712 y 3 031 valores, sin borrar filas
previous	recorte al percentil 99 (9)	rango intercuartil cero, la regla de Tukey no aplica

Resultado 44 923 filas y 15 columnas de entrada.

T1. pdays y el umbral de contacto previo

Tasa de sí según los días desde el último contacto



- Nunca contactado responde sí el 9.2 % de las veces (línea roja)
- Hasta 239 días la tasa se mantiene muy por encima de la base
- Entre 240 y 364 días cae a 12 % y 8.6 %, ya se comporta como nunca contactado
- Desde 365 días la tasa vuelve a subir a 27 %, pero son 691 filas (1.5 %) y se asumen bajo el mismo umbral
- Umbral elegido 240 días. contactado_antes vale 1 si pdays está entre 0 y 240, y pdays se deja en 240 para el resto

T2. Codificación y estandarización


Todo queda numérico para la herramienta de clasificación

Tipo	Variables	Método	Columnas
binaria	default, housing, loan, contactado_antes	0 y 1	4
ordinal	education	1 primary, 2 secondary, 3 tertiary	1
nominal	job, marital, contact, poutcome	one hot, sin poutcome_unknown por redundante	20
numérica	age, balance, campaign, pdays, previous, dia_anio	z score, media cero y desviación uno	6

- De 15 columnas de entrada se pasa a 31, todas numéricas
- Las indicatoras y education no se escalan, ya están en una escala corta y así se pueden redondear en el sobremuestreo
- Con todo numérico KNN funciona, cada categórica distinta entre dos clientes suma un salto fijo a la distancia

T3. Balanceo por dos caminos

Submuestreo de la clase no (T3_1) y sobremuestreo sintético de la clase sí (T3_2)



- T3_1. Se toman al azar 5 255 no para igualar a los 5 255 sí, quedan 10 510 filas
- T3_2. Se crean 34 413 sí sintéticos entre cada positivo y uno de sus cinco vecinos más cercanos, quedan 79 336 filas
- En T3_2 las indicadoras y education se redondean para no crear clientes con medio oficio
- El sobremuestreo se hace antes de partir, así que los sintéticos quedan al lado de sus originales en la validación cruzada

Resultados en Classification Learner

Mejor modelo de cada versión, validación cruzada de 5 particiones

Versión	Filas	Mejor modelo	Exactitud	Sí acertados	No acertados
T0	45 211	Narrow Neural Network	90.6 %	2 632 de 5 289 (49.8 %)	96.0 %
T1	44 923	Boosted Trees	89.4 %	828 de 5 255 (15.8 %)	99.1 %
T2	44 923	Boosted Trees	89.4 %	818 de 5 255 (15.6 %)	99.1 %
T3_1	10 510	Boosted Trees	71.1 %	2 943 de 5 255 (56.0 %)	84.8 %
T3_2	79 336	Fine KNN	90.8 %	38 439 de 39 668 (96.9 %)	84.7 %

- Predecir siempre no ya da 88.3 % de exactitud, por eso la exactitud sola dice poco
- T0 gana por duration, que es información posterior a la llamada. Sin ella la exactitud baja un punto y el modelo casi deja de acertar los sí
- T1 y T2 dan lo mismo, la codificación y el escalado no cambian el resultado de los árboles

Lectura de los resultados

Qué versión conviene usar

- T3_1 pierde exactitud global pero pasa de acertar el 16 % de los sí a acertar el 56 %, que es lo que le interesa al banco
- T3_2 da el mejor número, 90.8 %, pero lo consigue Fine KNN con un solo vecino, que encuentra al lado de cada sintético el positivo original del que salió
- Esa cifra está inflada por hacer el sobremuestreo antes de partir. Para confiar en ella habría que sobremuestrear solo dentro del entrenamiento de cada partición
- La versión honesta es T3_1, y la mejora real frente a T2 es de sensibilidad, no de exactitud
- Referencias
 - Moro, S., Cortez, P. y Rita, P. (2014). A data driven approach to predict the success of bank telemarketing. Decision Support Systems, 62, 22 a 31
 - Tukey, J. W. (1977). Exploratory Data Analysis. Addison Wesley