

Bank Marketing

Preparación del dataset paso a paso para la herramienta de clasificación

Sergio Duarte

Inteligencia Computacional. Maestría en Ciencias de la Información y las Comunicaciones

Universidad Distrital Francisco José de Caldas

El dataset

UCI Machine Learning Repository, Bank Marketing (Moro, Cortez y Rita, 2014)

- Campañas telefónicas de un banco portugués entre mayo de 2008 y noviembre de 2010
- Objetivo. Predecir si el cliente suscribe un depósito a plazo (variable y)
- 45 211 registros, 16 atributos de entrada y la clase
- Sin valores faltantes explícitos, pero varias categóricas usan la etiqueta unknown
- Clase muy desbalanceada, 39 922 no frente a 5 289 sí (11.7 % de positivos)
- Archivo bank-full.csv, separado por punto y coma
- Plan de trabajo en cuatro pasos sobre el dato
 - T0 crudo, tal como viene
 - T1 arreglo de columnas, filas, faltantes y atípicos
 - T2 codificación, estandarización y normalización
 - T3 balanceo de clases, por submuestreo y por sobremuestreo


Variables

Tres grupos según la documentación original

Grupo	Variable	Tipo	Observación
Cliente	age	numérica	18 a 95 años
Cliente	job	categorica 12 niveles	incluye unknown (288), quedan 11 niveles
Cliente	marital	categorica 3 niveles	divorced agrupa divorciados y viudos
Cliente	education	categorica ordinal	primary, secondary, tertiary, unknown (1 857)
Cliente	default, housing, loan	binarias yes/no	crédito en mora, hipoteca, préstamo personal
Cliente	balance	numérica	saldo medio anual en euros, cola muy larga
Último contacto	contact	categorica 3 niveles	unknown en el 29 % de las filas
Último contacto	day, month	numérica y categorica	fecha del último contacto sin año
Último contacto	duration	numérica	segundos de la llamada, se conoce después de llamar
Campaña	campaign	numérica	contactos en esta campaña
Campaña	pdays	numérica	días desde la campaña anterior, -1 si nunca
Campaña	previous	numérica	contactos antes de esta campaña
Campaña	poutcome	categorica 4 niveles	unknown en el 82 % de las filas

T0. Distribución de las numéricas


Histogramas de las siete variables numéricas y de la clase



- age es la única con una distribución aproximadamente simétrica
- balance, campaign y previous presentan colas muy pronunciadas
- pdays es casi toda -1 (82 % nunca contactados)
- duration se concentra en llamadas cortas
- day cubre todo el mes de forma casi uniforme
- y desbalanceada, 7.5 no por cada sí

T0. Diagramas de caja









Cada variable en su propia escala



- balance con valores hasta 102 127 y mínimo de -8 019
- campaign con hasta 63 llamadas a un mismo cliente
- previous con un caso de 275 contactos
- pdays y previous tienen rango intercuartil cero, la regla de Tukey no sirve ahí
- age muestra pocos atípicos, mayores de 70 años

T0. Categóricas y valores unknown

El dataset no trae faltantes, pero unknown cumple ese papel



Variable	unknown	Decisión
job	288 (0.6 %)	se eliminan las filas
education	1 857 (4.1 %)	se imputa con la moda del oficio
contact	13 020 (28.8 %)	se conserva como categoría
poutcome	36 959 (81.7 %)	coincide con nunca contactado

- month muy concentrado en mayo
- default casi constante, 1.8 % en mora
- Las unknown de poutcome coinciden con las filas de previous igual a cero salvo cinco casos

T1. Arreglo de columnas


Menos columnas y con significado, con intervención mínima sobre el dato

Columna	Tratamiento	Por qué
duration	se elimina	solo se conoce al terminar la llamada, es fuga de información hacia la clase
day y month	se unen en dia_anio (1 a 365)	una sola columna numérica en vez de una numérica y una categórica de 12 niveles
education	ordinal 1, 2, 3	los niveles tienen orden natural, no hace falta one hot
education unknown	moda dentro de cada job	el oficio es el mejor indicio del nivel educativo
job unknown	se eliminan 288 filas	no hay con qué imputar y son el 0.6 %
contact unknown	se conserva	es cerca del 29 % del dato y tiene comportamiento propio
pdays	dos campos, ver siguiente lámina	el -1 es un código de ausencia, no una cantidad de días

Para dia_anio se usa un año no bisiesto de referencia porque el dataset no trae el año. Resultado 44 923 filas y 15 columnas de entrada.

T1. pdays y el umbral de contacto previo


Tasa de sí según los días desde el último contacto



- Nunca contactado responde sí el 9.2 % de las veces (línea roja)
- Hasta 239 días la tasa se mantiene muy por encima de la base
- Entre 240 y 364 días cae a 12 % y 8.6 %, ya se comporta como nunca contactado
- Desde 365 días la tasa vuelve a subir a 27 %, pero son 691 filas (1.5 %) y se asumen bajo el mismo umbral para no abrir un tercer caso
- Umbral elegido 240 días, unos ocho meses
- `contactado_antes` vale 1 si `pdays` está entre 0 y 240
- `pdays` se deja en 240 para el resto, así el -1 desaparece

T1. Atípicos

Regla de 1.5 veces el rango intercuartil, recortando al borde



Variable	Fuera del rango	Tratamiento
age	480	recorte al borde superior 70.5
balance	4 712	recorte a -1 962 y 3 462
campaign	3 031	recorte a 6
previous	IQR cero	recorte al percentil 99 (9)
pdays	IQR cero	ya acotada por el umbral
education, dia_anio	sin atípicos	sin tratamiento

- Se recorta al borde en vez de borrar filas para no perder varios miles de filas
- Los 5 255 registros de la clase sí son escasos y eliminar filas los reduciría todavía más

T2. Codificación



Todo queda numérico para la herramienta de clasificación

Tipo	Variables	Método	Columnas
binaria	default, housing, loan, contactado_antes	0 y 1	4
ordinal	education	1 primary, 2 secondary, 3 tertiary	1
nominal	job	one hot	11
nominal	marital	one hot	3
nominal	contact	one hot	3
nominal	poutcome	one hot sin unknown	3
numérica	age, balance, campaign, pdays, previous, dia_anio	sin cambio	6

- poutcome_unknown se elimina por redundancia, se deduce de las otras tres indicadoras y marca a los nunca contactados, que ya identifica contactado_antes
- De 15 columnas de entrada se pasa a 31, todas numéricas

T2. Estandarización y normalización


Sobre age, balance, campaign, pdays, previous y día_anio. Las indicatoras, contactado_antes y education se quedan como están



- T2z con z score, media cero y desviación uno
- T2n con escalado al rango 0 a 1
- pdays se ve concentrada porque el 90 % de las filas vale 240 y el resto queda por debajo
- previous sigue concentrada en cero, es la variable con menos información
- Se guardan las dos versiones para comparar en la herramienta

T3. Balanceo por dos caminos

Submuestreo de la clase no (T3_1) y sobremuestreo sintético de la clase sí (T3_2)



- T3_1. Se toman al azar 5 255 no para igualar a los 5 255 sí, quedan 10 510 filas
- T3_2. Se crean 34 413 sí sintéticos entre cada positivo y uno de sus cinco vecinos más cercanos, quedan 79 336 filas
- En T3_2 las indicatoras se redondean para que sigan valiendo 0 o 1 y education para que siga en 1, 2 o 3
- No se duplican filas porque la copia y su original caen en particiones distintas y la prueba deja de ser independiente
- Con los sintéticos el riesgo baja pero no desaparece, la comparación entre T3_1 y T3_2 debe leerse con esa reserva
- Semilla fija en los dos caminos y las mismas filas en la versión z y en la versión n

Categóricas y numéricas mezcladas

Efecto sobre la distancia en KNN y sobre el sobremuestreo

- Tras T2 todo es numérico, las one hot y las binarias valen 0 o 1, education va de 1 a 3 y las seis numéricas están en z score o en rango 0 a 1
- Dos clientes con distinto oficio difieren en dos columnas one hot, así que la distancia euclídea suma un salto fijo por cada categórica distinta
- Con z score las numéricas pesan más que las indicadoras, con rango 0 a 1 quedan en la misma escala, por eso se comparan las versiones z y n
- KNN sirve, pero conviene la distancia euclídea sobre la versión n, o la distancia de Manhattan, que trata cada columna por igual
- Los árboles y los modelos de conjunto no dependen de la escala y manejan las indicadoras sin problema
- En T3_2 se redondean las indicadoras y education para no crear clientes con valores intermedios en oficio, estado civil o nivel educativo, que no tienen interpretación

Resumen de las versiones del dato

Tablas que quedan en bank_pasos.mat

Paso	Filas	Columnas de entrada	No	Sí	Qué cambió
T0	45 211	16	39 922	5 289	dato crudo
T1	44 923	15	39 668	5 255	sin duration, dia_anio, education ordinal, pdays con umbral, atípicos recortados
T2z y T2n	44 923	31	39 668	5 255	one hot, binarias en 0 y 1, z score o rango 0 a 1
T3_1z y T3_1n	10 510	31	5 255	5 255	submuestreo de la clase no
T3_2z y T3_2n	79 336	31	39 668	39 668	sobremuestreo sintético de la clase sí

- Un solo live script, procesar_bank.mlx, genera las cinco versiones y las figuras
- Cada tabla lleva la clase y como última columna
- Ninguna versión modifica la clase ni elimina positivos reales, salvo las 34 filas con job unknown

Siguiente paso. Herramienta de clasificación

Qué se va a comparar en Classification Learner

- Importar cada tabla desde el workspace con y como respuesta
- Validación cruzada de 5 particiones en todas las pruebas
- El escalado y el sobremuestreo se hicieron sobre todo el conjunto porque la partición se delega a la herramienta, así que las cifras de T3_2 salen algo optimistas
- Comparar T2z, T3_1z y T3_2z para ver el efecto de cada balanceo sobre la sensibilidad de la clase sí
- Comparar T2z frente a T2n para evaluar la sensibilidad de cada modelo al escalado
- Mirar la exactitud, pero sobre todo la matriz de confusión, porque con 88 % de la clase no la exactitud resulta poco informativa
- Referencias
 - Moro, S., Cortez, P. y Rita, P. (2014). A data driven approach to predict the success of bank telemarketing. Decision Support Systems, 62, 22 a 31
 - Tukey, J. W. (1977). Exploratory Data Analysis. Addison Wesley