

Bank Marketing. Revisión estadística de variables y efecto de cada corrección sobre los modelos

Actividad 1, Inteligencia Computacional. Dataset 222 del repositorio UCI, campañas telefónicas de un banco portugués.

Bitácora

El zip de UCI trae varios archivos y lo primero fue decidir cuál usar. `bank.csv` es una muestra del 10 por ciento, así que quedó descartado. `bank-additional-full.csv` tiene 20 predictoras e incluye variables macroeconómicas del país, que es otro problema distinto. Me quedé con `bank-full.csv`, que son 45.211 registros con 16 predictoras y la variable objetivo, y lo dejé anotado para que no parezca arbitrario.

Cargué el archivo y lo primero que revisé fue si había faltantes. MATLAB me dijo que cero NaN y casi me lo creo. Mirando las categóricas una por una aparecieron 36.959 registros con `poutcome` en "unknown" y 13.020 con `contact` en "unknown". Los faltantes estaban ahí, solo que escritos como texto. Y revisando las numéricas encontré que `pdays` vale menos uno en 36.954 registros, que según la documentación significa "nunca lo habían contactado antes". O sea que ese menos uno tampoco es un número, es una etiqueta metida dentro de una columna numérica. Un mapa de calor de nulos, que es la técnica que sugiere la guía para faltantes, no habría mostrado absolutamente nada en este dataset.

La segunda cosa que encontré leyendo la documentación de UCI fue más incómoda. Dice explícitamente que `duration`, la duración de la llamada, solo se conoce después de hacer la llamada, y que si la llamada dura cero segundos la respuesta es "no" por definición. Es fuga de información pura. Y efectivamente es la variable con mayor tamaño de efecto de todas, con una d de Cohen de 1,336, precisamente porque hace trampa. Sacarla del modelo hunde el desempeño, y esa caída es el resultado correcto.

Con 45.211 registros las pruebas estadísticas cambian de sentido. Todo sale significativo. Las 7 variables numéricas rechazan normalidad con p ridículamente pequeño, y las 7 salen significativas al comparar entre clases con Welch. El p valor deja de informar. Por eso todo lo que hay aquí de comparación entre clases va acompañado del tamaño del efecto, que es lo único que separa una diferencia real de una diferencia detectable solo porque tengo 45 mil datos. El ejemplo que mejor lo muestra es `age`, con p de $1,6e-05$ y una diferencia de medias de 0,83 años.

También me tocó programar Shapiro Wilk y D'Agostino Pearson, porque MATLAB no las trae, y validarlas por simulación antes de usarlas. Esa comprobación quedó como el paso 0 y es común a los dos datasets de la actividad.

Después armé seis versiones del dataset, desde el crudo hasta uno con selección de variables, y entrené sobre cada una con validación cruzada de 5 pliegues. Aquí el balanceo se hizo por submuestreo y no por SMOTE, y esa decisión, que tomé por tamaño de muestra, terminó teniendo una consecuencia que no había previsto: el submuestreo aplicado antes de particionar no infla las

métricas, mientras que SMOTE aplicado antes de particionar sí las infla bastante. La comparación completa está al final.

Todo se corre con `run_todo` y usa semilla fija, así que los números se repiten idénticos. Los resultados numéricos completos están en [Resultados_Bank.xlsx](#).

Comprobación previa de las dos pruebas que programé

`swtest.m` implementa Shapiro Wilk con el algoritmo de Royston y `dagostino_k2.m` implementa D'Agostino Pearson. Como son código propio, hay que verificarlos antes de sacar conclusiones con ellos. La verificación se hizo con MATLAB mismo por simulación, sin depender de nada externo.

La idea es simple. Si genero datos que sí son normales y le paso la prueba 2000 veces con alfa de 0,05, una prueba bien calibrada debe rechazar la normalidad aproximadamente el 5 por ciento de las veces. Si rechaza mucho más es alarmista y si rechaza mucho menos es sorda. Además sus p valores deberían repartirse de forma uniforme entre 0 y 1.


Prueba	n	Rechaza	Debería rechazar	Desvío	p de uniformidad
Shapiro Wilk, propia	30	5,05 %	5 %	+0,0005	0,683
D'Agostino K ² , propia	30	5,30 %	5 %	+0,0030	0,004
Lilliefors, de MATLAB	30	4,45 %	5 %	-0,0055	no aplica
Anderson Darling, de MATLAB	30	4,85 %	5 %	-0,0015	0,328
Shapiro Wilk, propia	100	5,65 %	5 %	+0,0065	0,580
D'Agostino K ² , propia	100	5,45 %	5 %	+0,0045	0,838
Lilliefors, de MATLAB	100	4,85 %	5 %	-0,0015	no aplica
Anderson Darling, de MATLAB	100	5,70 %	5 %	+0,0070	0,877
Shapiro Wilk, propia	336	5,65 %	5 %	+0,0065	0,257
D'Agostino K ² , propia	336	6,00 %	5 %	+0,0100	0,769
Lilliefors, de MATLAB	336	5,55 %	5 %	+0,0055	no aplica
Anderson Darling, de MATLAB	336	5,40 %	5 %	+0,0040	0,867

Las cuatro pruebas quedan entre 4,45 y 6,00 por ciento cuando deberían dar 5, o sea dentro de lo esperable con 2000 repeticiones. Las dos funciones propias se comportan igual de bien que las nativas de MATLAB, que es lo que había que demostrar.

La única anotación es que D'Agostino con n de 30 da un p de uniformidad de 0,004, o sea que sus p valores no se reparten del todo uniforme con muestras chicas. Tiene explicación: la aproximación de

D'Agostino Pearson es asintótica y por eso la función exige un mínimo de 20 datos. Con n de 100 y de 336 el problema desaparece.

Reparto de los p valores cuando los datos SI son normales (n = 336, 2000 repeticiones)



Los cuatro histogramas deberían ser planos. Los de las dos funciones propias lo son. Los de Lilliefors se ven cortados porque MATLAB trunca ese p valor al rango de su tabla interna, entre 0,001 y 0,5, así que la prueba de uniformidad no le aplica.


La segunda comprobación es al revés. Genero datos que no son normales y miro cuántas veces la prueba se da cuenta. Con n grande todas las pruebas detectan prácticamente todo y no se distinguen, así que la comparación se hace con n de 30, que es donde se separan.

Distribución	Shapiro Wilk, propia	D'Agostino K ² , propia	Lilliefors	Anderson Darling
Exponencial	96,6 %	78,8 %	80,2 %	94,1 %
Uniforme	36,6 %	40,2 %	15,0 %	28,5 %
t de Student con 5 gl	24,5 %	29,3 %	16,4 %	21,9 %
Lognormal con sigma 0,25	25,9 %	23,2 %	15,3 %	22,1 %

Y la misma tabla con n de 336, para ver cómo se cierra la brecha al crecer la muestra.

Distribución	Shapiro Wilk, propia	D'Agostino K ² , propia	Lilliefors	Anderson Darling
Exponencial	100 %	100 %	100 %	100 %
Uniforme	100 %	100 %	99,95 %	100 %
t de Student con 5 gl	95,0 %	95,4 %	74,7 %	90,7 %
Lognormal con sigma 0,25	100 %	99,8 %	92,4 %	99,4 %

Aquí sale un matiz que vale la pena documentar. Shapiro Wilk es la mejor detectando asimetría, que es el caso de la exponencial y de la lognormal. D'Agostino gana cuando el problema está en las colas, que es el caso de la uniforme y de la t de Student, lo cual tiene sentido porque su estadístico está construido justamente sobre asimetría y curtosis. Y Lilliefors es la más floja de las cuatro en todos los escenarios, con diferencias grandes: en la t de Student con n de 336 detecta el 74,7 por ciento cuando las otras andan por el 90 y pico. Eso coincide con lo que dice la guía cuando la califica de menos potente que Shapiro Wilk.



Con muestras chicas ninguna prueba domina en todo. Shapiro Wilk gana contra la asimetría y D'Agostino contra las colas raras. Con muestras del tamaño de este dataset la comparación deja de tener sentido porque todas llegan al 100 por ciento.

Vale aclarar que en este dataset Shapiro Wilk se corre sobre una submuestra aleatoria de 5.000 registros, porque la aproximación de Royston pierde validez por encima de ese tamaño. Para el total se usan Lilliefors y Anderson Darling.

El dataset y cómo quedó tipificado

45.211 registros y 17 columnas. Las 16 primeras son predictoras y la última es la clase. El significado de cada una viene del archivo `bank-names.txt` que trae el propio dataset.

Las primeras ocho describen al cliente.

Variable	Tipo	Qué es	Valores
age	numérica discreta	edad del cliente en años	de 18 a 95
job	categorica nominal	tipo de trabajo	12 niveles: admin., unknown, unemployed, management, housemaid, entrepreneur, student, blue collar, self employed, retired, technician, services
marital	categorica nominal	estado civil, donde divorced	married, divorced, single

		incluye también viudo	
education	categorica ordinal	nivel educativo alcanzado	unknown, primary, secondary, tertiary
default	binaria	si tiene algún crédito en mora	yes, no
balance	numérica continua	saldo medio anual de la cuenta, en euros	de -8.019 a 102.127
housing	binaria	si tiene crédito de vivienda	yes, no
loan	binaria	si tiene crédito de consumo	yes, no

Las cuatro siguientes describen el último contacto de la campaña actual.

Variable	Tipo	Qué es	Valores
contact	categorica nominal	medio por el que se hizo el contacto	cellular, telephone, unknown
day	numérica discreta	día del mes del último contacto	de 1 a 31
month	categorica nominal cíclica	mes del último contacto	los 12 meses abreviados en inglés
duration	numérica continua	duración del último contacto, en segundos	de 0 a 4.918

Las cuatro últimas son el historial de contactos del cliente.

Variable	Tipo	Qué es	Valores
campaign	numérica discreta	número de contactos hechos a este cliente durante esta campaña, incluyendo el último	de 1 a 63
pdays	numérica discreta	días transcurridos desde que se contactó al cliente en una campaña anterior	de 0 a 871, y el valor -1 significa que nunca se le había contactado
previous	numérica discreta	número de contactos hechos a este cliente antes de esta campaña	de 0 a 275
poutcome	categorica nominal	resultado de la campaña de marketing anterior	success, failure, other, unknown

Y la variable objetivo.

Variable	Tipo	Qué es	Valores
y	binaria	si el cliente terminó contratando el depósito a plazo	yes con 5.289 casos, no con 39.922

Resumiendo la tipificación, quedan siete numéricas, que son **age**, **balance**, **day**, **duration**, **campaign**, **pdays** y **previous**, nueve categóricas, que son **job**, **marital**, **education**, **default**, **housing**, **loan**, **contact**, **month** y **poutcome**, y la clase binaria **y**.

Hay tres cosas de esta tipificación que condicionan todo lo que viene después.

La primera es que **duration** no debería usarse para predecir. La duración de una llamada solo se conoce cuando la llamada ya terminó, así que no está disponible en el momento en que uno querría decidir a quién llamar. La documentación del dataset lo advierte de forma explícita.

La segunda es que **pdays** mezcla dos informaciones en una sola columna. Cuando vale un número positivo es una cantidad de días, y cuando vale -1 es una etiqueta que significa "nunca contactado". Un modelo que la reciba tal cual va a tratar ese -1 como si fuera una cantidad de días.

La tercera es que **education** es ordinal, porque primary, secondary y tertiary tienen un orden natural, pero el nivel unknown no encaja en esa escala. En este trabajo se trató como nominal y se convirtió a columnas indicadoras, que es la opción conservadora.

Sobre las variables derivadas que aparecen más adelante, en la etapa B1 se crea **contactado_antes**, que vale 1 si el cliente había sido contactado en una campaña anterior y 0 si no, y **pdays** se deja en 0 cuando no aplica. Las nueve categóricas se convierten en columnas indicadoras de cero y uno, con nombres del tipo **job_management** o **poutcome_success**, una por cada nivel salvo el primero.

Faltantes disfrazados

El dataset no tiene ni un solo NaN, y ahí está la trampa. Los faltantes vienen codificados como texto dentro de las categorías.

Variable	Categorías	Registros en "unknown"	Porcentaje
poutcome	4	36.959	81,7
contact	3	13.020	28,8
education	4	1.857	4,1
job	12	288	0,64


Y aparte de eso, **pdays** vale menos uno en 36.954 registros, el 81,7 por ciento. Ese menos uno no es un número de días, es la etiqueta "nunca lo habían contactado". Si se deja como número, el modelo entiende literalmente que a esos clientes se les contactó hace menos un días, y cualquier distancia euclidiana calculada entre menos uno y trescientos es basura.

Sobre los "unknown" tomé la decisión de dejarlos como categoría propia y no imputarlos. Con el 81,7 por ciento de **poutcome** en esa categoría, imputar habría sido inventar. Sobre **pdays** sí hubo corrección, y está explicada en la sección de etapas.

Descriptivos

Variable	Media	Mediana	Desv	Mín	Máx	IQR	Asimetría	Curtosis
age	40,94	39	10,62	18	95	15	0,68	3,32
balance	1.362	448	3.045	-8.019	102.127	1.356	8,36	143,7
day	15,81	16	8,32	1	31	13	0,09	1,94
duration	258,2	180	257,5	0	4.918	216	3,14	21,15
campaign	2,76	2	3,10	1	63	2	4,90	42,25
pdays	40,20	-1	100,1	-1	871	0	2,62	9,93
previous	0,58	0	2,30	0	275	0	41,85	4.509

Bank - histogramas de las variables numericas (dato crudo)



`'balance'`, `'duration'`, `'campaign'` y `'previous'` tienen colas larguísimas. `'pdays'` se ve bimodal por culpa del menos uno.


`previous` con curtosis de 4.509 es un caso de manual. Casi todos los valores son cero y hay un cliente con 275 contactos previos.

Y hay algo que rompe la receta estándar. `pdays` y `previous` tienen IQR igual a cero, porque más del 75 por ciento de los registros vale lo mismo. Con IQR de cero la regla de Tukey marca como atípico todo valor distinto del cuartil, y winsorizar dejaría la variable convertida en una constante. Es un caso donde aplicar el procedimiento a ciegas destruye el dato, y se trata aparte.

Balance de la variable objetivo

Clase	N	Porcentaje
no	39.922	88,30
yes	5.289	11,70

La prueba binomial exacta contra la hipótesis de 50 y 50 devuelve un p valor por debajo de $2,2e-308$, que es el mínimo representable en doble precisión, así que MATLAB entrega cero exacto. No es un error de cálculo, es desborde, y conviene decirlo así en vez de reportar un cero. El chi cuadrado de bondad de ajuste da 26.529,9 con un grado de libertad. La razón de desbalance es de 7,55 a 1.



Siete clientes y medio que dicen que no por cada uno que dice que sí.

La consecuencia práctica es la que importa. Un modelo que diga siempre "no" acierta el 88,30 por ciento. Ese es el piso contra el que hay que comparar todo, y no el 50 por ciento.

Normalidad

Con 45.211 registros hice dos cosas distintas. Shapiro Wilk sobre una submuestra aleatoria de 5.000, porque por encima de ese tamaño la aproximación pierde validez, y Lilliefors más Anderson Darling sobre el total.

Variable	p Shapiro sobre 5.000	p Lilliefors	p Anderson Darling	Asimetría	Curtosis
age	1,6e-35	menor a 0,001	menor a 0,0005	0,68	3,32
balance	1,3e-77	menor a 0,001	menor a 0,0005	8,36	143,7
day	2,0e-35	menor a 0,001	menor a 0,0005	0,09	1,94
duration	1,6e-68	menor a 0,001	menor a 0,0005	3,14	21,15
campaign	1,8e-76	menor a 0,001	menor a 0,0005	4,90	42,25
pdays	9,8e-82	menor a 0,001	menor a 0,0005	2,62	9,93
previous	1,4e-85	menor a 0,001	menor a 0,0005	41,85	4.509

Cero de siete. Ruta no paramétrica sin discusión. Vale la pena anotar que con este tamaño de muestra las pruebas de normalidad casi no informan, porque cualquier desviación mínima sale significativa. Los que sí informan son la asimetría, la curtosis y los Q-Q plots.


Homogeneidad de varianzas y comparación entre las dos clases

Levene y Bartlett rechazan homocedasticidad en las siete variables, y el p más alto de todos es el de **day** con 0,0127. Sin normalidad y sin homocedasticidad, el t de Student clásico queda descartado, así que se reportan Welch y Mann Whitney junto con el tamaño del efecto.

Variable	Diferencia de medias	p Student	p Welch	p Mann Whitney	d de Cohen	r biserial	Efecto al menos pequeño
duration	+316,1	menor a 1e-300	menor a 1e-300	menor a 1e-300	1,336	0,615	sí
pdays	+32,3	3,8e-108	7,3e-78	2,5e-235	0,324	0,186	sí
previous	+0,67	7,8e-88	1,4e-71	3,5e-283	0,291	0,205	sí
campaign	-0,71	1,0e-54	3,7e-112	1,9e-71	-0,228	-0,145	sí
balance	+500,6	2,5e-29	4,4e-23	6,6e-101	0,165	0,180	no
day	-0,73	1,7e-09	3,4e-09	3,3e-10	-0,088	-0,053	no
age	+0,83	8,8e-08	1,6e-05	0,063	0,078	-0,016	no

Este es el punto más importante de toda la revisión de este dataset. Las siete variables salen significativas con Welch, o sea siete de siete, pero solo cuatro tienen un tamaño de efecto que llegue siquiera al umbral de "pequeño", que se suele poner en 0,2 de d de Cohen.

El caso de **age** lo resume. El p valor da 1,6e-05, aparentemente contundente, pero la diferencia de medias es de 0,83 años y la d de Cohen es 0,078. Con 45 mil datos una diferencia de diez meses de edad es estadísticamente detectable y prácticamente irrelevante. Y el detalle final es que Mann Whitney ni siquiera la encuentra significativa, con p de 0,063, porque las medianas no se mueven. Reportar solo el p valor del t test aquí sería directamente engañoso.



En `age` las dos cajas son casi idénticas, que es lo que dice la d de Cohen y no lo que dice el p valor.


Las categóricas contra la clase

Variable	Niveles	Chi cuadrado	gl	p	V de Cramér	Mínimo esperado	Cumple la regla del 5
poutcome	4	4.391,5	3	menor a 1e-300	0,312	176,8	sí
month	12	3.061,8	11	menor a 1e-300	0,260	25,0	sí
contact	3	1.035,7	2	1,3e-225	0,151	340,0	sí
housing	2	875,7	1	1,9e-192	0,139	2.349	sí
job	12	836,1	11	3,3e-172	0,136	33,7	sí
education	4	238,9	3	1,6e-51	0,073	217,2	sí
loan	2	210,2	1	1,2e-47	0,068	847,4	sí
marital	3	196,5	2	2,1e-43	0,066	609,1	sí
default	2	22,7	1	1,9e-06	0,022	95,3	sí

Las nueve cumplen la regla del conteo esperado mayor o igual a 5, así que el test exacto de Fisher no hace falta y por eso no se aplicó. Es una de las pruebas de la guía que se revisó, se determinó que no correspondía y se documenta la razón en vez de correrla por correrla.

Otra vez todas dan un p ridículamente pequeño y otra vez es la V de Cramér la que ordena de verdad. **poutcome** con 0,312 sí discrimina. **default** con 0,022 es prácticamente ruido pese a su p de 1,9e-06.

Bank - tasa de contratación por categoría (línea roja = tasa global 11.7%)




La línea roja es la tasa global de 11,7 por ciento. En `poutcome` igual a success contrata el 64,7 por ciento y en marzo la tasa llega al 52 por ciento. `poutcome` y `month` son las que más se despegan, que es lo que decía la V de Cramér.

Correlación y multicolinealidad

Entre las numéricas no hay nada preocupante. El VIF queda entre 1,01 y 1,28 en las siete y el número de condición de la matriz estandarizada es 1,7. Tiene sentido, porque son variables de naturaleza muy distinta entre sí: edad, saldo, día del mes, número de contactos.


Bank - mapas de calor de correlacion entre numericas



La correlación más alta es entre `pdays` y `previous`, y ni siquiera llega a niveles problemáticos.

Relevancia de las variables frente a la clase

El ranking se hizo con MRMR sobre una tabla mixta, con numéricas y categóricas juntas, de modo que los puntajes son comparables entre los dos tipos.



`duration` encabeza, como era de esperar tratándose de la variable con fuga de información.

Este ranking hay que mirarlo con lupa, porque no coincide con la V de Cramér. MRMR pone a **default** en tercer lugar cuando es justamente la categórica con la asociación más débil de todas. No es un error de cálculo. MRMR pondera la relevancia dividida por la redundancia, y **default** vale "no" en el 98 por ciento de los registros, así que no se parece a ninguna otra variable y su redundancia sale bajísima. Cuando todas las relevancias son pequeñas ese cociente se vuelve inestable y premia a las variables raras aunque no aporten.

Es un argumento más para no casarse con un solo criterio de selección. Aquí la V de Cramér es más creíble que el MRMR, y de hecho la etapa B5, que se construyó siguiendo el ranking MRMR, terminó empeorando todos los modelos.

Atípicos

Variable	IQR	Atípicos por IQR	Porcentaje	Atípicos por z mayor a 3	Porcentaje
age	15	487	1,08	381	0,84
balance	1.356	4.729	10,46	745	1,65
day	13	0	0,00	0	0,00
duration	216	3.235	7,16	963	2,13
campaign	2	3.064	6,78	840	1,86
pdays	0	8.257	18,26	1.723	3,81
previous	0	8.257	18,26	582	1,29

Las filas con al menos un atípico son 17.018, o sea el 37,6 por ciento del dataset. Borrar filas queda descartado de entrada.

Y como ya se dijo, en **pdays** y **previous** la regla del IQR ni siquiera está bien definida, porque su IQR es cero. Los 8.257 "atípicos" de cada una no son atípicos, son simplemente los valores distintos del centinela.

Las seis etapas del dataset

Todas las etapas quedan en matriz numérica. Las categóricas se convierten en columnas indicadoras de cero y uno, una por nivel menos el primero, que se deja fuera para no crear columnas linealmente dependientes entre sí. Siete numéricas más 35 indicadoras dan 42 columnas. Se hizo así porque KNN, LDA y la regresión logística necesitan números, y además es lo que Classification Learner termina haciendo internamente con esos modelos.

Etapa	Qué se hizo	Filas	Columnas	no y yes	IR
B0 crudo	one hot de las categóricas, incluye duration y pdays con el menos uno	45.211	42	39.922 y 5.289	7,55
B1 correcciones	fuera duration, pdays partido en bandera más valor, winsorización	45.211	42	39.922 y 5.289	7,55
B2 balanceado	submuestreo aleatorio de la clase no hasta 50	10.578	42	5.289 y 5.289	1,00

	y 50				
B3 estandarizado	B2 con z score	10.578	42	5.289 y 5.289	1,00
B4 normalizado	B2 reescalado a 0 y 1	10.578	42	5.289 y 5.289	1,00
B5 selección	B3 con las 20 columnas mejor rankeadas por MRMR	10.578	20	5.289 y 5.289	1,00


Conviene aclarar que B3 y B4 son ramas alternativas sobre B2, no pasos encadenados.

Las tres decisiones de B1, en orden de importancia.

La primera es que **se elimina `duration`**. La documentación de UCI lo dice de frente: la duración de la llamada solo se conoce después de hacerla, y si la llamada dura cero segundos la respuesta es "no" por definición. Usarla es predecir con información del futuro. No es casualidad que sea la variable con mayor efecto de todas, con d de Cohen de 1,336, lo es precisamente porque hace trampa.

La segunda es que **`pdays` se parte en dos**. Se crea una bandera binaria **contactado_antes**, con valores cero y uno, y el valor numérico se pone en cero cuando no aplica. Así se separa "no lo habían contactado" de "lo contactaron hace X días", que son dos informaciones distintas metidas en la misma columna.


La tercera es una **winsorización selectiva**. Se aplica 1,5 por IQR solo en **age**, **balance** y **campaign**, que son las que tienen IQR mayor que cero, y eso toca 7.860 filas, el 17,4 por ciento. En **pdays** y **previous** se recortó el percentil 99 en su lugar, dejando **pdays** en 370, lo que tocó 385 valores, y **previous** en 9, lo que tocó 361 valores.



En el boxplot se ve que **`pdays`** y **`previous`** siguen siendo casi constantes. Son variables con IQR cero y ninguna winsorización las arregla.

Sobre B2 hay que ser explícito con lo que se pierde. El submuestreo tira 34.633 registros de la clase **no**, que es el 76,6 por ciento de esa clase. Es una pérdida enorme de información. Se eligió sobre

SMOTE porque con 5.289 registros de la clase **yes** quedan 10.578 filas, que alcanzan de sobra para entrenar, mientras que sobremuestrear habría dejado 79.844 filas con 34.633 registros inventados, más lento en Classification Learner y, como se ve al final, más peligroso.



El precio de llegar a 50 y 50 es botar tres cuartas partes de la clase mayoritaria.

Los modelos

Cuatro clasificadores en todas las etapas y un quinto solo en las balanceadas, con validación cruzada de 5 pliegues.


El árbol aguanta variables mezcladas y no le afecta la escala. El KNN es justo lo contrario y debería ser el que más note el escalado. El LDA es la ruta paramétrica clásica. La regresión logística es el modelo de referencia para un problema binario como este. El SVM lineal se corrió solo en las etapas de 10.578 filas, porque con 45.211 el entrenamiento se dispara y no aporta nada nuevo al análisis.

Naive Bayes se dejó por fuera a propósito. Asume que las predictoras son independientes dentro de cada clase, y las columnas indicadoras de una misma variable categórica son mutuamente excluyentes, o sea lo más dependiente que puede haber. Aplicarlo aquí sería violar su supuesto central de forma estructural y no accidental.

Etapas	Modelo	Exactitud	Exactitud balanceada	Kappa	Recall de yes	Precisión de yes	F1 de yes
B0 crudo	Árbol	0,883	0,705	0,420	0,474	0,498	0,486
B0 crudo	KNN	0,882	0,617	0,291	0,270	0,494	0,349
B0 crudo	LDA	0,900	0,699	0,452	0,437	0,601	0,506
B0 crudo	Logística	0,883	0,500	-0,0001	0,000	0,000	0,000
B1 correcciones	Árbol	0,854	0,619	0,252	0,312	0,358	0,334
B1 correcciones	KNN	0,876	0,545	0,130	0,113	0,392	0,176
B1 correcciones	LDA	0,890	0,624	0,318	0,276	0,561	0,370
B1	Logística	0,883	0,500	-0,0001	0,0002	0,100	0,0004

correcciones							
B2 balanceado	Árbol	0,650	0,650	0,299	0,645	0,651	0,648
B2 balanceado	KNN	0,600	0,600	0,200	0,562	0,608	0,584
B2 balanceado	LDA	0,701	0,701	0,402	0,638	0,730	0,681
B2 balanceado	Logística	0,676	0,676	0,351	0,676	0,676	0,676
B2 balanceado	SVM	0,695	0,695	0,389	0,571	0,759	0,652
B3 estandarizado	Árbol	0,648	0,648	0,296	0,644	0,649	0,646
B3 estandarizado	KNN	0,687	0,687	0,373	0,648	0,702	0,674
B3 estandarizado	LDA	0,701	0,701	0,402	0,638	0,730	0,681
B3 estandarizado	Logística	0,702	0,702	0,404	0,635	0,733	0,680
B3 estandarizado	SVM	0,695	0,695	0,389	0,571	0,759	0,651
B4 normalizado	Árbol	0,649	0,649	0,297	0,643	0,650	0,647
B4 normalizado	KNN	0,684	0,684	0,367	0,649	0,697	0,672
B4 normalizado	LDA	0,701	0,701	0,402	0,638	0,730	0,681
B4 normalizado	Logística	0,702	0,702	0,404	0,636	0,733	0,681
B4 normalizado	SVM	0,695	0,695	0,389	0,571	0,759	0,651
B5 selección	Árbol	0,630	0,630	0,259	0,622	0,632	0,627
B5 selección	KNN	0,662	0,662	0,325	0,639	0,670	0,654
B5 selección	LDA	0,690	0,690	0,379	0,635	0,713	0,672
B5 selección	Logística	0,689	0,689	0,379	0,630	0,715	0,670
B5 selección	SVM	0,685	0,685	0,370	0,585	0,731	0,650

Antes de leerla, una advertencia. Las exactitudes de B0 y B1 no se comparan de frente con las de B2 a B5, porque la referencia de "predecir siempre la clase mayoritaria" vale 0,883 en las primeras y 0,500 en las segundas. Por eso el Excel incluye la columna de mejora sobre la base.



Arriba la exactitud simple con la tasa base marcada. Abajo la exactitud balanceada. La primera no distingue nada y la segunda sí.

Visto por modelo, quién llega más alto y qué tan sensible es a cómo le llegue el dato.

Modelo	Mejor	En la etapa	Peor	En la etapa	Diferencia
Árbol	0,7054	B0 crudo, con fuga	0,6189	B1 correcciones	0,087
Logística	0,7021	B4 normalizado	0,5000	B0 crudo	0,202
LDA	0,7010	B2 balanceado	0,6238	B1 correcciones	0,077
SVM	0,6946	B2 balanceado	0,6849	B5 selección	0,010
KNN	0,6866	B3 estandarizado	0,5450	B1 correcciones	0,142

El 0,7054 del árbol está marcado porque es la etapa que todavía tiene **duration**. Descontando esa, el mejor resultado legítimo del dataset es la regresión logística sobre B4 con 0,7021, prácticamente empatada con B3.


La columna de la diferencia vuelve a ser la más informativa. La regresión logística es el modelo más sensible al preprocesamiento, con 0,202 entre su mejor y su peor versión, y el SVM el más estable con 0,010, porque **templateSVM** estandariza internamente y ya trae puesta la corrección que a los demás hay que darles.

Lo que se lee de la tabla completa es lo siguiente.

La regresión logística en B0 y B1 predice "no" para absolutamente todos los clientes. Exactitud de 0,883, idéntica a la tasa base, exactitud balanceada de 0,500, kappa de menos 0,0001 y recall de la clase **yes** igual a cero. Si uno mirara solo la exactitud, este modelo parecería tan bueno como los demás y en realidad es inútil. Es la demostración más limpia de por qué la exactitud no sirve con clases desbalanceadas.

Quitar **duration** en B1 hunde el desempeño. El árbol cae de 0,705 a 0,619 de exactitud balanceada y el KNN de 0,617 a 0,545. Eso confirma que esa sola variable cargaba casi toda la señal, y confirma también que había que quitarla, porque ese 0,705 no era real.

Balancear en B2 sube el recall de la clase **yes** de 0,312 a 0,645 en el árbol. Ese es el objetivo del negocio, porque al banco le interesa detectar a quién llamar y no acertar en los que van a decir que no.




Cuántos de los clientes que sí contratan detecta cada modelo en cada etapa.

Estandarizar en B3 es donde este dataset brilla. El KNN salta de 0,600 a 0,687, que son 8,7 puntos, y la logística de 0,676 a 0,702. En cambio el árbol y el LDA no se mueven ni una milésima. Es exactamente lo esperado: el árbol parte por umbrales, que son invariantes a transformaciones monótonas, y el LDA ya estandariza implícitamente al invertir la matriz de covarianza. El KNN, que compara distancias euclidianas, estaba dominado por **balance**, que llega a 102.127, frente a columnas que solo valen cero o uno.

Normalizar en B4 da prácticamente lo mismo que estandarizar, con diferencias de más o menos 0,003. Con este tipo de datos da igual cuál de las dos se use.

La selección de variables en B5 empeora todo, entre 1,0 y 2,4 puntos abajo en los cinco modelos. Quedarse con 20 de 42 columnas pierde información útil.




Matriz de confusión del mejor modelo sin fuga de información.

Balancear antes de partir, y por qué aquí no infla

Cuando uno balancea el dataset completo y después se lo pasa a Classification Learner, la validación cruzada está partiendo un conjunto que ya fue modificado. Para medir si eso importa, hice la validación cruzada a mano aplicando el submuestreo solo dentro del bloque de entrenamiento de cada pliegue.

Modelo	Submuestreo antes de partir	Submuestreo dentro del pliegue	Diferencia
Árbol	0,6496	0,6473	0,0023
KNN	0,5998	0,5961	0,0037
LDA	0,7010	0,7047	-0,0037
Logística	0,6757	0,6851	-0,0093

El promedio de la diferencia es 0,0000, con signos mezclados. O sea que aquí balancear antes de particionar no infla nada.



Las dos barras de cada par son prácticamente iguales.

Esto contrasta con lo que ocurre en el otro dataset de la actividad, donde el balanceo se hizo con SMOTE y el inflado promedio fue de 0,0738 puntos. La explicación es la naturaleza del método. El submuestreo solo elimina filas, no crea información nueva, así que el bloque de prueba nunca se contamina. SMOTE en cambio construye puntos sintéticos interpolando vecinos, y si se aplica antes de partir, esos sintéticos se derivaron de puntos que van a terminar en el bloque de prueba.


La lección práctica es concreta. Un CSV balanceado por submuestreo se puede cargar en Classification Learner y el número que sale es confiable. Uno balanceado con SMOTE, no.

Hay un segundo efecto que sí importa en este dataset y conviene verlo. En la validación honesta el bloque de prueba conserva la proporción real de 88 y 12, y ahí las métricas de la clase minoritaria cambian mucho.

Métrica del LDA	Con el CSV balanceado	Con la proporción real
Recall de yes	0,638	0,639
Precisión de yes	0,730	0,269

El recall es el mismo, pero la precisión se derrumba de 0,73 a 0,27. Con el CSV balanceado parece que 7 de cada 10 clientes marcados van a contratar, y en la realidad son menos de 3. La exactitud balanceada del CSV balanceado sí es honesta, pero la precisión no lo es, y eso hay que saberlo antes de prometerle algo al área comercial.

Bank. Resumen del efecto de cada correccion sobre los modelos



Los cuatro resultados del dataset en una sola figura.

Lo que no funcionó

Intento	Resultado	Por qué
Quitar duration	el desempeño cae entre 6 y 9 puntos	era la variable que cargaba la señal, pero era fuga de información y había que sacarla
Selección de variables en B5	entre 0,010 y 0,024 por debajo	quedarse con 20 de 42 columnas pierde información útil
Normalizar en vez de estandarizar	empate técnico	con estos datos las dos hacen lo mismo
Regla de 1,5 por IQR en pdays y previous	inaplicable	su IQR es cero y winsorizar las volvería constantes
Ranking MRMR como criterio de selección	contradice a la V de Cramér	con relevancias todas pequeñas el cociente relevancia sobre redundancia se vuelve inestable
Exactitud simple como métrica	inservible	la tasa base ya es 0,883 y la logística la iguala prediciendo siempre "no"

Cómo revisarlo en Classification Learner

Los CSV de cada etapa están en [resultados/bank/etapas/](#), son seis y todos tienen la clase en la última columna con el nombre `clase`.

Se abre con Apps, Classification Learner, New Session, From File, se selecciona el CSV y se pone **clase** como Response. Hay que dejar Cross Validation con 5 folds para que los números sean comparables con los de este informe.

Lo que más vale la pena mirar es el KNN entrenado sobre **bank_B2_balanceado.csv** y después sobre **bank_B3_estandarizado.csv**. Ahí está el salto de 8,7 puntos que produce el escalado. Y al leer los resultados de **bank_B0_crudo.csv** hay que cambiar la métrica que muestra la app, porque la exactitud va a decir 88 por ciento y no significa nada cuando la tasa base ya es 88,3.

Limitaciones

Los hiperparámetros no se ajustaron. El KNN va con k igual a 5 fijo, el árbol sin podar, el SVM lineal. La comparación es entre etapas del dataset y no entre modelos, así que mantenerlos fijos es lo correcto, pero significa que ninguno de estos números es el mejor alcanzable.

Se usó una sola semilla, la 42. No hay repeticiones ni intervalos de confianza, así que diferencias menores a 0,01 no deberían interpretarse como reales.

Los "unknown" se dejaron como categoría propia. Con el 81,7 por ciento de **poutcome** en esa categoría, imputar habría sido inventar, pero tampoco se probó la alternativa de eliminar la variable.

El SVM no se corrió sobre las etapas de 45.211 filas por costo computacional, así que para B0 y B1 hay un modelo menos en la comparación.

Anexo. Qué pruebas de la guía se aplicaron y cuáles no

Sección de la guía	Prueba	Estado
1	Tipificación, descriptivos, histogramas, boxplots, Q-Q	aplicada
2	Shapiro Wilk	aplicada sobre submuestra de 5.000, programada y validada por simulación
2	Kolmogorov Smirnov con Lilliefors	aplicada sobre el total
2	Anderson Darling	aplicada sobre el total
2	D'Agostino Pearson K ²	aplicada, programada y validada por simulación
3	Levene	aplicada
3	Bartlett	aplicada
3	Fligner Killeen	no aplicada, no es nativa de MATLAB y Levene ya cubre el caso robusto
4	t de Student	aplicada
4	t de Welch	aplicada, es la que se reporta por la heterocedasticidad
4	Mann Whitney U	aplicada
5	ANOVA y Kruskal Wallis	no aplican, la clase es binaria
6	Pearson y Spearman	aplicadas
6	Kendall	no aplicada, es de orden n al cuadrado y con 45.211 filas es inviable
7	Chi cuadrado de independencia	aplicada a las nueve categóricas
7	Test exacto de Fisher	no hizo falta, ninguna celda esperada quedó por debajo de 5
7	V de Cramér	aplicada, y es la que ordena de verdad
8	ANOVA F para selección	aplicada, equivale al cuadrado del estadístico t con dos clases
8	Chi cuadrado para selección	aplicada

8	Información mutua mediante MRMR	aplicada sobre tabla mixta
9	Matriz de correlación con mapa de calor	aplicada
9	VIF	aplicada
9	Número de condición	aplicada
10	Z score	aplicada
10	Regla de 1,5 por IQR	aplicada, con la excepción documentada de las variables con IQR cero
10	Grubbs	no aplicada, detecta un solo atípico y exige normalidad, que no hay
10	Mahalanobis	no aplicada, con 35 columnas indicadoras la distancia pierde sentido
11	Prueba binomial	aplicada
11	Chi cuadrado de bondad de ajuste	aplicada como respaldo por el desborde de precisión
12	Wilcoxon pareado, McNemar, Q de Cochran	no aplican, no hay datos pareados
13.1	Histograma, boxplot, Q-Q	aplicados
13.2	Boxplot por clase	aplicado
13.3	Matriz de dispersión	no aplicada, con 42 columnas es ilegible
13.4	Mapa de calor de correlación	aplicado
13.5	Barras por categoría contra la clase	aplicado como tasa de contratación por categoría
13.6	Boxplot de atípicos	aplicado
13.7	PCA	aplicado
13.7	t-SNE y UMAP	no aplicados, sirven para mirar pero no cambian ninguna decisión de esta actividad
13.8	Mapa de valores faltantes	reemplazado por la tabla de "unknown", que es donde estaban los faltantes de verdad

Anexo. Funciones que hubo que programar

Archivo	Qué hace	Por qué existe
swtest.m	Shapiro Wilk con el algoritmo de Royston	MATLAB no la trae y la guía la pide como principal
dagostino_k2.m	D'Agostino Pearson K^2	tampoco es nativa
cramersv.m	Chi cuadrado más V de Cramér	MATLAB da el chi cuadrado pero no el tamaño del efecto
calcular_vif.m	Factor de inflación de la varianza	no es nativo
tratar_outliers.m	Winsorización o eliminación por 1,5 por IQR, con protección para IQR igual a 0	
smote_simple.m	SMOTE básico con k vecinos	MATLAB no trae SMOTE
balancear.m	SMOTE, sobremuestreo o submuestreo	
metricas_clf.m	Exactitud, exactitud balanceada, F1 macro, kappa, recall y precisión de la clase positiva	
evaluar_cv.m	Validación cruzada manual con balanceo y escalado dentro del pliegue	es lo que permite medir la fuga
guardar_fig.m	Exporta PNG con fondo blanco	R2026a dibuja en tema oscuro por defecto

