Series de tiempo. Taller 2

Benchmarking de SARIMAX y NARX sobre la concentración diaria de PM2.5 en Beijing

Informe

Asignatura: Inteligencia Computacional Aplicada
Docente: Cesar Andrey Perdomo Charry
Estudiante: Sergio Santiago Duarte Rojas
Código: 20261595002

Fecha: 11 de noviembre de 2026

Universidad Distrital Francisco José de Caldas

Índice

1. Introducción **2**

2. Marco teórico (resumen) **2**

3. Metodología **2**
3.1. Datos y validación previa 2
3.2. Diagnóstico y decisiones de diseño 2
3.3. Modelos, rejillas y selección 3

4. Resultados **4**

5. Análisis **5**
5.1. Origen de la ventaja de la red 5
5.2. Sensibilidad de los hiperparámetros 6
5.3. Prueba externa y residuos 6

6. Conclusiones **6**

7. Declaración de uso de inteligencia artificial **7**

8. Referencias **7**

1. Introducción

Se pronosticó a 24 días la concentración media diaria de PM2.5 en la estación Aotizhongxin de Beijing. En la prueba externa, la red autorregresiva no lineal con entradas exógenas (NARX) obtuvo una raíz del error cuadrático medio de 44.0, frente a 70.2 del modelo autorregresivo integrado de media móvil estacional con regresores exógenos (SARIMAX) y 96.2 del ingenuo estacional. La diferencia entre NARX y SARIMAX es significativa ($p = 0.003$).

El análisis busca de dónde proviene esa ventaja. Sin temperatura, punto de rocío, presión y velocidad del viento, los dos modelos quedan casi iguales en desarrollo, así que la explicación está en el uso de la meteorología. Los hiperparámetros se eligieron por validación cruzada de origen móvil dentro del bloque de desarrollo. La prueba externa se evaluó una sola vez, al final.

2. Marco teórico (resumen)

SARIMAX combina una estructura ARIMA estacional con una regresión lineal sobre variables exógenas (Box et al., 2015). Su pronóstico a varios pasos converge, al alejarse del origen, a la media condicionada por las exógenas, y su efecto sobre la serie es lineal en la escala en que se modela. La red NARX aproxima la relación entre los retardos de la salida y de las exógenas con un perceptrón multicapa (Leontaritis y Billings, 1985). En lazo cerrado cada predicción entra como retardo de la siguiente. El error se propaga así a lo largo del horizonte, más cuanto mayor es el peso que la red da a los retardos de la salida.

Cuando el modelo se ajusta sobre $z = \log(1 + y)$ con error aproximadamente normal, $\exp(\hat{z})$ estima la mediana y no la media. La transformación inversa $\exp(\hat{z} + \hat{\sigma}^2/2) - 1$ corrige ese sesgo. La fuerza de la tendencia F_T y de la estacionalidad F_S se calcula a partir de la descomposición estacional y de tendencia por regresión local (STL) y toma valores entre 0 y 1 (Hyndman y Athanasopoulos, 2021). La validación cruzada de origen móvil entrena con la historia anterior a cada origen y evalúa el bloque siguiente, lo que respeta el orden temporal (Bergmeir y Benítez, 2012). La prueba de Diebold y Mariano (1995) con la corrección de Harvey et al. (1997) compara la pérdida cuadrática de dos modelos, y un estadístico positivo favorece al segundo del par. La prueba de Ljung y Box (1978) evalúa la autocorrelación remanente en los residuos.

3. Metodología

3.1 Datos y validación previa

Los datos son los registros horarios de la estación Aotizhongxin entre el 1 de marzo de 2013 y el 28 de febrero de 2017, publicados en el repositorio UCI (Chen, 2017) y descritos por Zhang et al. (2017). El cuaderno los agrega a promedios diarios, lo que da 1461 días, e imputa por interpolación temporal 15 días sin dato de PM2.5. El 80 % inicial (1168 días, hasta el 11 de mayo de 2016) forma el bloque de desarrollo y los 293 días restantes la prueba externa. La Tabla 1 reúne los criterios de validación del cuaderno.

3.2 Diagnóstico y decisiones de diseño

En el bloque de desarrollo las pruebas de Dickey-Fuller aumentada (ADF, $p < 0.001$) y de Kwiatkowski-Phillips-Schmidt-Shin (KPSS, $p \geq 0.10$) coinciden en que la serie es estacionaria en nivel, por lo que no se diferencia ($d = D = 0$). La fuerza de la estacionalidad semanal es baja ($F_S = 0.071$), igual que la de la tendencia ($F_T = 0.200$). Entre las exógenas, la velocidad del viento es la de

Tabla 1
Validación previa del conjunto de datos

Criterio	Evidencia	Cumple
C1 Índice monótono y sin duplicados	verificación automática del cuaderno	sí
C2 Muestreo regular	paso modal de una hora	sí
C3 Faltantes en el objetivo $\leq 10\,\%$	2.64 % de horas sin PM2.5	sí
C4 Longitud ≥ 10 periodos estacionales	1461 días frente a 70	sí
C5 Exógenas existentes y numéricas	TEMP, DEWP, PRES y WSPM	sí
C6 Objetivo no constante	desviación positiva	sí
C7 Origen, licencia y unidades	UCI, CC BY 4.0, µg/m^3, °C, hPa y m/s	sí
C8 Exógenas disponibles al pronosticar	pronóstico meteorológico a 24 días, supuesto conocido	con reserva

Nota. C7 y C8 se documentan de forma manual. La reserva de C8 se discute en el análisis.

mayor correlación con PM2.5 ($r = -0.38$). La serie tiene una cola derecha extensa, con días por encima de 400 µg/m^3, y ambos modelos trabajan sobre $\log(1 + y)$ con la corrección de sesgo de la transformación inversa.

Antes de definir las rejillas se compararon variantes de diseño con la misma validación cruzada (Tabla 2). En SARIMAX el criterio de Akaike favorece el orden $(3, 0, 0)$, pero ese orden produce un error medio de 92.9 en la validación cruzada, por pronósticos inestables, y se descartó como punto de partida.

Tabla 2
Raíz del error cuadrático medio en la validación cruzada de las variantes de diseño

Variante	**SARIMAX** $(1, 0, 1)$	**NARX** $d_y = 3$**, 8 neuronas**
Diseño adoptado	49.95	38.84
Sin exógenas	57.77	57.11
Sin logaritmo	51.83	43.78
Sin corrección de sesgo	50.79	–
Solo exógenas contemporáneas ($d_x = 0$)	–	41.66

Nota. El diseño adoptado usa el logaritmo, las cuatro exógenas y la corrección de sesgo. Cinco pliegues de origen móvil dentro del bloque de desarrollo, horizonte de 24 días. NARX con semilla 2026. Cifras de la sección 13 del cuaderno.

3.3 Modelos, rejillas y selección

El modelo clásico es un SARIMAX con constante sobre $\log(1 + y)$ y las cuatro exógenas como regresores, ajustado con statsmodels (Seabold y Perktold, 2010). La red NARX recibe $\log(1 + y)$ en los retardos $1, \ldots, d_y$ y las exógenas en t y $t - 1$ ($d_x = 1$), estandarizadas con la media y la desviación del entrenamiento de cada pliegue. Tiene una capa oculta tanh, regularización $L_2 = 10^{-4}$ y optimizador Adam, con parada temprana (paciencia de 30 épocas) sobre el 15 % final del entrenamiento del pliegue. La varianza de los residuos de ese tramo alimenta la corrección de sesgo. El pronóstico se construye en lazo cerrado.

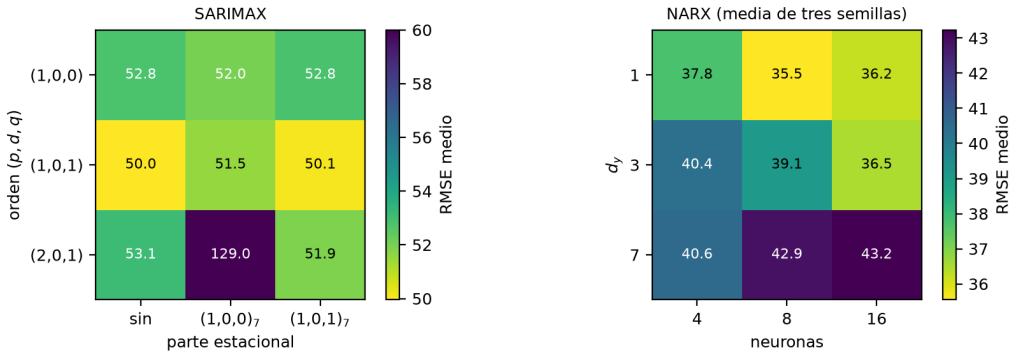
Las rejillas cruzan tres órdenes no estacionales $\{(1, 0, 0), (1, 0, 1), (2, 0, 1)\}$ con tres partes estacionales $\{\text{ninguna}, (1, 0, 0)_7, (1, 0, 1)_7\}$ en SARIMAX, y $d_y \in \{1, 3, 7\}$ con $\{4, 8, 16\}$ neuronas y las semillas 1, 2 y 3 en NARX. Cada combinación se evalúa en cinco pliegues de ventana expandible con orígenes en el 40 % final del desarrollo y horizonte de 24 días. Se elige la combinación de menor error medio, y en la red ese error se promedia sobre las tres semillas. Los modelos elegidos se evalúan después en 12 orígenes de la prueba externa. Las dos particiones y los modelos elegidos, ajustados sobre el desarrollo, acompañan al cuaderno.

4. Resultados

La selección fijó SARIMAX $(1,0,1)$ sin parte estacional y NARX con $d_y = 1$ y 8 neuronas. La Figura 1 muestra las dos superficies de sensibilidad y la Tabla 3 las métricas en la validación cruzada y en la prueba externa.

Figura 1

Raíz del error cuadrático medio en la validación cruzada según los hiperparámetros



Nota. La escala de SARIMAX se corta en 60 para que la combinación inestable no oculte las demás diferencias.

Tabla 3

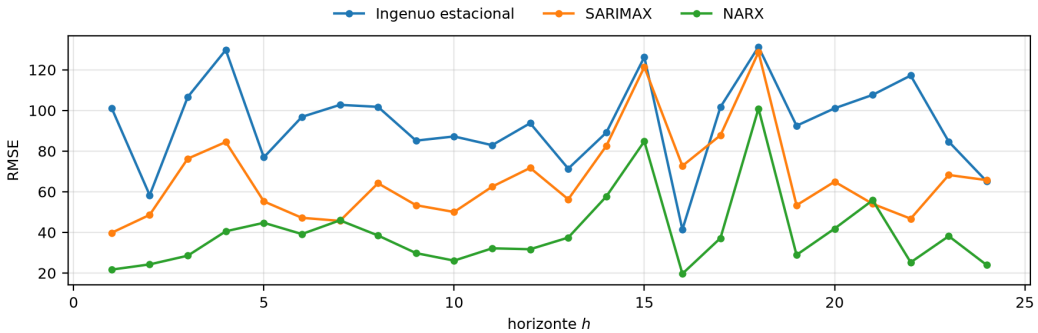
Métricas de los modelos elegidos en la validación cruzada y en la prueba externa

	Validación cruzada				Prueba externa			
Modelo	RMSE	MAE	MAPE	MASE	RMSE	MAE	MAPE	MASE
Ingenuo estacional	110.53	71.69	194.2	1.005	96.24	69.49	175.6	0.974
SARIMAX $(1,0,1)$	51.47	37.06	109.2	0.519	70.18	49.63	110.6	0.696
NARX $d_y = 1$, 8 neuronas	40.07	28.81	80.0	0.404	44.02	28.75	53.5	0.403

Nota. RMSE, raíz del error cuadrático medio. MAE, error absoluto medio. MAPE, error porcentual absoluto medio, en porcentaje. MASE, error absoluto medio escalado con el error del ingenuo estacional en el bloque de desarrollo. La red final usa la semilla 2026 del cuaderno. En el cuaderno, SARIMAX y NARX conservan los nombres Clásico y Neuronal de la plantilla.

Figura 2

Raíz del error cuadrático medio por horizonte en la prueba externa



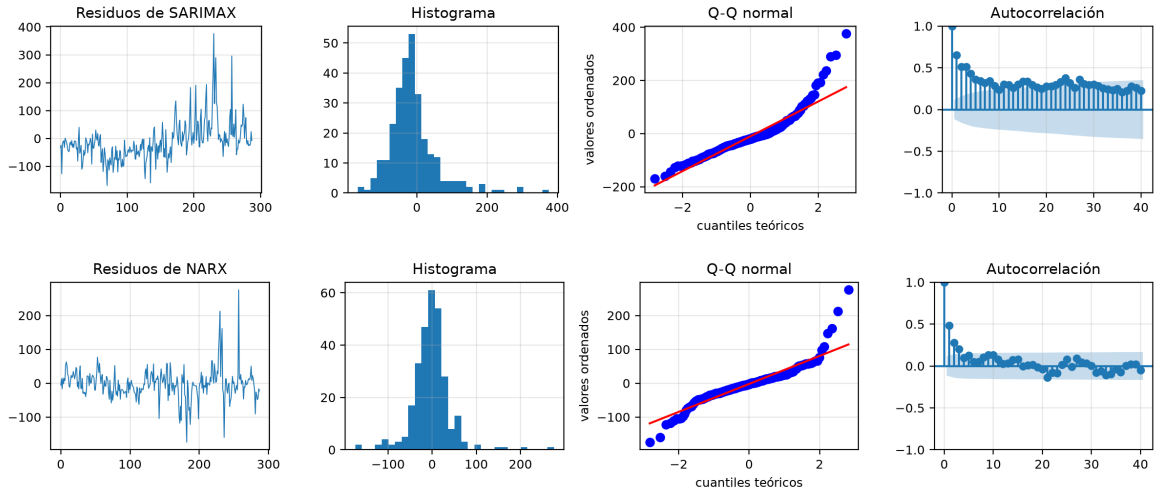
Nota. Cada punto promedia los 12 orígenes de la prueba externa.

En la prueba de Diebold y Mariano a 24 pasos, NARX supera a SARIMAX (DM*= 2.98,

$p = 0.003$) y al ingenuo (DM*= 2.43, $p = 0.016$), mientras que la diferencia entre el ingenuo y SARIMAX no es significativa al 5 % (DM*= 1.74, $p = 0.083$). La prueba de Ljung y Box en el retardo 7 rechaza la ausencia de autocorrelación en los tres modelos, con estadísticos de 102.3 para el ingenuo, 437.3 para SARIMAX y 110.8 para NARX.

Figura 3

Residuos de SARIMAX (arriba) y de NARX (abajo) en la prueba externa



Nota. Residuos de los 12 orígenes concatenados en orden temporal. El residuo es el valor observado menos el pronóstico.

5. Análisis

5.1 Origen de la ventaja de la red

Sin exógenas, SARIMAX y NARX obtienen 57.8 y 57.1 en la validación cruzada (Tabla 2). La red elegida, con $d_y = 1$ y 8 neuronas, queda sin exógenas entre 55.4 y 57.0 según la semilla. Con la sola historia de PM2.5 ninguna estructura saca ventaja. Con las mismas cuatro exógenas, SARIMAX baja a 50.0 y la red a 38.8. La diferencia está en el uso de la meteorología. En SARIMAX el efecto de cada variable es un coeficiente constante sobre el logaritmo, y en la red depende del valor de las demás entradas. El retardo de un día en las exógenas reduce el error de la red de 41.7 a 38.8. El tiempo del día anterior pesa sobre la concentración de hoy, como documentan Zhang et al. (2017) para esta red de estaciones. El logaritmo también favorece más a la red (de 43.8 a 38.8) que a SARIMAX (de 51.8 a 50.0), porque reduce el rango de la variable de salida que la capa tanh debe cubrir.

El mismo hecho explica por qué $d_y = 1$ resultó el mejor número de retardos. En lazo cerrado, con un solo retardo de la salida, el pronóstico se apoya en la meteorología futura después de pocos pasos, y el error de NARX por horizonte no crece de forma sostenida (Figura 2). Esto también señala la principal reserva del estudio (criterio C8). El cuaderno supone conocida la meteorología de los 24 días siguientes. En operación, esas entradas provendrían de un pronóstico meteorológico con error propio, que crece con el horizonte y afectaría más a la red, cuya ventaja depende de ellas. Las cifras de la prueba corresponden a meteorología observada.

5.2 Sensibilidad de los hiperparámetros

La superficie de SARIMAX es plana, con errores entre 50.0 y 53.1 en ocho de las nueve combinaciones (Figura 1). La parte estacional no mejora el ajuste, porque $(1, 0, 1)$ con $(1, 0, 1)_7$ obtiene 50.1 frente a 50.0 sin ella, coherente con $F_S = 0.071$. La combinación $(2, 0, 1)$ con $(1, 0, 0)_7$ alcanza 129.0 con una desviación entre pliegues de 152.7, señal de que la predicción diverge en alguno de los pliegues. Lo mismo ocurrió con el orden $(3, 0, 0)$ que eligió el criterio de Akaike. Un buen ajuste dentro de la muestra no garantizó un pronóstico estable a 24 días, y la validación cruzada lo detectó.

En la red, d_y es el factor dominante. Con un retardo el error medio queda entre 35.5 y 37.8, y con siete entre 40.6 y 43.2. El número de neuronas interactúa con los retardos. Con $d_y = 1$ y $d_y = 3$, pasar de 4 a 16 neuronas reduce el error, y con $d_y = 7$ lo aumenta, porque más entradas y más neuronas elevan la varianza del estimador sin que los retardos lejanos aporten información, dada la estacionalidad semanal baja. La desviación entre semillas va de 0.1 a 2.8. La red final, entrenada con la semilla 2026 del cuaderno, obtiene 40.1 en la validación cruzada frente a la media de 35.5 de las tres semillas de la rejilla. Esa dispersión es mayor que la diferencia entre las tres mejores combinaciones (35.5, 36.2 y 36.5), cuyo orden no queda establecido, pero es menor que la distancia de cerca de diez unidades o más que separa cualquier configuración de NARX con $d_y \leq 3$ del mejor SARIMAX.

5.3 Prueba externa y residuos

SARIMAX empeora de 51.5 en la validación cruzada a 70.2 en la prueba, un aumento del 36 %, mientras que NARX pasa de 40.1 a 44.0 y conserva el mismo error absoluto medio (28.8). Los residuos de SARIMAX son negativos en la primera mitad de la prueba, que corresponde a los meses de verano y otoño de 2016 con concentraciones bajas, y grandes y positivos en los episodios del invierno siguiente (Figura 3). Su autocorrelación se mantiene entre 0.25 y 0.5 hasta el retardo 40. El modelo sobrestima los periodos limpios y subestima los episodios, y ese error persistente explica también su error porcentual absoluto medio de 110.6 %, que penaliza la sobrestimación en niveles bajos, frente al 53.5 % de la red.

Los residuos de NARX solo muestran autocorrelación significativa en los tres primeros retardos. Con pronósticos a 24 pasos desde un mismo origen esa dependencia corta es esperable, porque los errores de horizontes consecutivos comparten la información disponible en el origen. Por eso Ljung y Box rechaza en los tres modelos. La comparación útil es la magnitud del estadístico, cuatro veces mayor en SARIMAX que en NARX. La misma persistencia explica que la diferencia entre el ingenuo y SARIMAX no resulte significativa pese a 96.2 frente a 70.2, ya que la prueba de Diebold y Mariano con horizonte 24 estima la varianza de largo plazo con 23 autocovarianzas y los errores autocorrelacionados la inflan.

En la Figura 2, los máximos en $h = 15$ y $h = 18$ son comunes a los tres modelos. Con 12 orígenes, el error de cada horizonte queda dominado por unos pocos días, y esos máximos corresponden a episodios que ningún modelo anticipó, no a un deterioro con el horizonte. En costo, NARX requiere cerca de 50 veces el tiempo de SARIMAX (141.6 frente a 2.7 s en la validación cruzada).

6. Conclusiones

La estacionalidad semanal de esta serie es baja, y la información predictiva está en la meteorología. Por eso, en este caso, elegir modelo es sobre todo elegir cómo usar las exógenas. Sin ellas, SARIMAX y NARX quedan casi iguales (Tabla 2). Con ellas, NARX con un retardo de la salida y ocho neuronas

supera a SARIMAX en la validación cruzada y en la prueba externa, con diferencia significativa (Tabla 3).

Fuera del periodo de desarrollo el contraste aumenta. La red mantiene su error, mientras que SARIMAX acumula errores persistentes según la estación (Figura 3).

Dos resultados tienen que ver con el método. El orden que favorecía el criterio de Akaike produce pronósticos inestables a 24 días, y la validación cruzada lo descartó (Sección 3.2). En la red, la variabilidad entre semillas no permite ordenar las mejores combinaciones, aunque no cambia la ventaja frente a SARIMAX. El alcance operativo de estas cifras se discute en la Sección 5.1.

7. Declaración de uso de inteligencia artificial

Se usó Claude como apoyo en la redacción, la revisión de consistencia entre conceptos y la preparación de tablas y gráficas. Los procedimientos, las modificaciones al código fuente y la estructura del documento son del autor, quien verificó cada cifra con las salidas del cuaderno.

8. Referencias

Bergmeir, C., & Benítez, J. M. (2012). On the use of cross-validation for time series predictor evaluation. *Information Sciences, 191*, 192–213. https://doi.org/10.1016/j.ins.2011.12.028

Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5.ª ed.). Wiley.

Chen, S. (2017). *Beijing multi-site air quality* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5RK5G

Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics, 13*(3), 253–263. https://doi.org/10.1080/07350015.1995.10524599

Harvey, D., Leybourne, S., & Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting, 13*(2), 281–291. https://doi.org/10.1016/S0169-2070(96)00719-4

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.ª ed.). OTexts. https://otexts.com/fpp3/

Leontaritis, I. J., & Billings, S. A. (1985). Input-output parametric models for non-linear systems Part I: Deterministic non-linear systems. *International Journal of Control, 41*(2), 303–328. https://doi.org/10.1080/00207178508961129

Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika, 65*(2), 297–303. https://doi.org/10.1093/biomet/65.2.297

Seabold, S., & Perktold, J. (2010). statsmodels: Econometric and statistical modeling with Python. En *Proceedings of the 9th Python in Science Conference* (pp. 92–96). https://doi.org/10.25080/Majora-92bf1922-011

Zhang, S., Guo, B., Dong, A., He, J., Xu, Z., & Chen, S. X. (2017). Cautionary tales on air-quality improvement in Beijing. *Proceedings of the Royal Society A, 473*(2205), 20170457. https://doi.org/10.1098/rspa.2017.0457