

Perceptrón simple y Adaline: implementación parametrizable en MATLAB y evaluación sobre compuertas lógicas, Iris y autenticación de billetes

Sergio Duarte

Maestría, Inteligencia Computacional Aplicada
sergioduartedev@gmail.com

Resumen—Este trabajo implementa en MATLAB una red de una sola neurona y una sola capa bajo dos modelos clásicos: el perceptrón simple, con tres reglas de corrección de pesos seleccionables, y el Adaline, con la regla delta sobre la salida lineal. Ambas implementaciones son completamente parametrizables en número de entradas, umbral, factor de aprendizaje, codificación de la salida y criterio de parada. Los modelos se evalúan primero sobre compuertas AND y OR de 2, 3 y 4 entradas, midiendo el número de épocas hasta convergencia sobre 20 inicializaciones aleatorias, y luego sobre dos conjuntos de datos reales, Iris y Banknote Authentication, particionados en proporciones 60-40, 70-30, 80-20 y 90-10. El perceptrón converge en todas las compuertas en menos de 20 épocas en promedio y alcanza 100 % de exactitud en el problema separable de Iris y hasta 99,3 % en billetes. El Adaline clasifica correctamente las compuertas en la mayoría de los casos, aunque como minimiza el error cuadrático y no el error de clasificación puede dejar patrones mal clasificados en las esquinas de la tabla de verdad, y en billetes alcanza 97,8 % siempre que las entradas estén escaladas: sin escalado el error diverge para $\alpha \geq 0,05$. Se documenta también el efecto de la codificación de la salida, que anula la primera regla de aprendizaje cuando se usa $\{0, 1\}$, y la imposibilidad de ambos modelos para resolver la XOR.

Index Terms—perceptrón, Adaline, regla delta, compuertas lógicas, separabilidad lineal, MATLAB

I. INTRODUCCIÓN

El perceptrón de Rosenblatt [1] y el Adaline de Widrow y Hoff [2] son los dos modelos de neurona artificial más antiguos que todavía se enseñan, y por una buena razón: con una sola neurona ya aparecen todos los conceptos que después escalan a redes profundas, es decir, pesos, umbral, función de activación, regla de aprendizaje, factor de aprendizaje, épocas y criterio de parada. La diferencia entre los dos modelos es sutil pero importante. El perceptrón corrige los pesos a partir del error de la salida binaria, de modo que solo corrige cuando se equivoca; el Adaline corrige a partir del error de la salida lineal, de modo que sigue ajustando aunque ya clasifique bien, buscando que la salida lineal se acerque al valor deseado.

Este documento corresponde al Taller 1 de la asignatura Inteligencia Computacional Aplicada y cubre sus doce puntos. Los puntos 1 a 6 piden un perceptrón parametrizable, probarlo en compuertas AND y OR de 2, 3 y 4 entradas, y después sobre particiones del conjunto Iris y del conjunto de autenticación de billetes. Los puntos 7 a 12 repiten lo mismo con el Adaline. Todo el código está en *live scripts* de MATLAB [3],

uno por bloque del taller, y las funciones de los dos modelos están en archivos aparte para reutilizarlos.

El resto del documento se organiza así. La sección II resume los dos modelos y sus reglas de aprendizaje. La sección III describe la implementación, los conjuntos de datos y el protocolo experimental. La sección IV presenta los resultados, primero del perceptrón y luego del Adaline. La sección V discute lo que salió distinto de lo esperado y la sección VI cierra.

II. MARCO TEÓRICO

II-A. Perceptrón simple

La neurona recibe n entradas $x_1, \dots, x_n$ y una entrada constante igual a 1 cuyo peso w_0 hace de sesgo. La suma ponderada es

$$z = w_0 + \sum_{i=1}^n w_i x_i, \quad (1)$$

y la salida se obtiene con una función escalón respecto de un umbral θ :

$$Y(x) = \begin{cases} y_{\max} & \text{si } z > \theta \\ y_{\min} & \text{en otro caso} \end{cases} \quad (2)$$

donde $\{y_{\min}, y_{\max}\}$ es la codificación elegida para la salida, típicamente $\{-1, 1\}$ o $\{0, 1\}$.

El taller pide que el script permita elegir entre tres formas de corrección de los pesos:

$$\Delta W_i = d(x) X_i \quad (3)$$

$$\Delta W_i = [d(x) - Y(x)] X_i \quad (4)$$

$$\Delta W_i = \alpha [d(x) - Y(x)] X_i \quad (5)$$

con $d(x)$ la salida deseada, $Y(x)$ la generada y α el factor relativo de aprendizaje, y el ajuste siempre es $W_i^* = W_i + \Delta W_i$. La regla (3) es la de tipo hebbiano vista en clase, se aplica solo cuando hay error y no usa la salida del modelo; la (4) es la regla del perceptrón original con $\alpha = 1$; la (5) es la misma con factor de aprendizaje. El teorema de convergencia del perceptrón garantiza que, si las clases son linealmente separables, la regla (5) encuentra un hiperplano separador en un número finito de correcciones [4].

Tabla I
PARÁMETROS DE LAS DOS FUNCIONES

Parámetro	Perceptrón	Adaline
Número de entradas	implícito en X	implícito en X
Regla de corrección	1, 2 o 3	solo (6)
Factor α	sí	sí
Umbral θ	del escalón	del escalón al clasificar
Codificación de salida	$[y_{\min}, y_{\max}]$	$[y_{\min}, y_{\max}]$
Criterio de parada	época sin errores	EC o $ \Delta EC $ mínimos
Tope de épocas	sí	sí
Semilla	sí	sí

II-B. Adaline y regla delta

El Adaline usa la misma suma ponderada, pero el error se calcula sobre la salida lineal $y = z$ y no sobre la salida del escalón. La regla delta minimiza el error cuadrático por descenso de gradiente:

$$\Delta W_i = \alpha [d(x) - y] X_i, \quad \Delta \theta = \alpha [d(x) - y], \quad (6)$$

y el entrenamiento se detiene cuando el error cuadrático de la época

$$EC = \frac{1}{2} \sum_{k=1}^Q \varepsilon_k^2, \quad \varepsilon_k = d^{(k)} - y^{(k)} \quad (7)$$

baja de un valor permitido, con Q el número de patrones. Para clasificar, la salida lineal se pasa por un escalón con umbral θ , en este trabajo $\theta = 0,5$ para salidas en $\{0, 1\}$. Como la regla delta es un descenso de gradiente, el factor α tiene un límite de estabilidad: si es demasiado grande el error crece en vez de bajar [4].

II-C. Separabilidad lineal

Una sola neurona con escalón solo puede representar funciones cuyas clases se separan con un hiperplano. Las compuertas AND y OR de cualquier número de entradas son linealmente separables; la XOR no lo es [5]. En Iris, la clase *setosa* es separable de las otras dos, mientras que *versicolor* y *virginica* se traslapan [6]. Estas propiedades se usan aquí como casos de prueba positivos y negativos.

III. METODOLOGÍA

III-A. Implementación

Se escribieron dos funciones, `perceptron.m` y `adaline.m`, con la misma interfaz: reciben la matriz de patrones X ($N \times n$), el vector de salidas deseadas d y una estructura de opciones. La Tabla I lista los parámetros. Cada función devuelve los pesos, el sesgo y una estructura con el histórico de la corrida. El sesgo se implementa como el peso w_0 de una entrada constante 1, que es exactamente el modelo de la figura del taller. Los pesos iniciales se toman de una distribución uniforme en $[0, 1]$ a partir de una semilla, para que cualquier corrida sea reproducible. Una función auxiliar `prededir.m` aplica la suma ponderada y el escalón, y sirve igual para los dos modelos.

En el perceptrón una época es una pasada por todos los patrones, y se declara convergencia cuando una época completa no requiere ninguna corrección, lo que equivale al contador `aux` del código de clase. En el Adaline se recorren los patrones uno a uno corrigiendo tras cada uno, como en el código `Adaline` de clase, y al final de la época se calcula (7). Hizo falta un segundo criterio de parada, además del error mínimo: con una tabla de verdad la salida lineal nunca calza exactamente con los ceros y unos deseados, el EC se estanca en un valor positivo y con solo el error mínimo el entrenamiento nunca terminaría. Por eso también se detiene cuando el cambio del EC entre dos épocas consecutivas cae por debajo de una tolerancia, por defecto 10^{-6} .

III-B. Conjuntos de datos

Compuertas. La función `compuerta.m` genera la tabla de verdad completa de AND, OR o XOR para n entradas en $\{0, 1\}$, con la salida codificada según se pida. Para $n = 2, 3, 4$ hay 4, 8 y 16 patrones.

Iris. 150 flores, cuatro medidas en centímetros y tres especies de 50 ejemplares cada una [6]. Como la neurona es una sola, se arman dos problemas binarios: (A) *setosa* contra las otras dos, que es linealmente separable, y (B) *versicolor* contra *virginica*, que no lo es.

Banknote. 1372 billetes descritos por cuatro estadísticos de la transformada *wavelet* de su imagen: varianza, asimetría, curtosis y entropía. La clase indica si el billete es auténtico (762 casos) o falso (610) [7]. Las cuatro variables están en escalas distintas; la curtosis, por ejemplo, va de $-5,3$ a $17,9$ mientras la entropía va de $-8,5$ a $2,4$.

III-C. Particiones

Siguiendo el script `Dataset_train_test` de clase, cada conjunto se mezcla una sola vez con `randperm` y semilla fija, y se corta en las proporciones 60-40, 70-30, 80-20 y 90-10. La única modificación al script original fue redondear el punto de corte, porque $0,9 \times 1372 = 1234,8$ no sirve como índice. En Iris las particiones tienen 90, 105, 120 y 135 ejemplos de entrenamiento; en billetes 823, 960, 1098 y 1235. Las entradas se escalan al rango $[0, 1]$ con los mínimos y máximos del conjunto de entrenamiento, y esos mismos valores se aplican al de prueba. En billetes se entrena además sin escalar para medir el efecto.

III-D. Protocolo experimental

En compuertas, como el resultado depende de los pesos iniciales, cada combinación de compuerta, número de entradas y parámetro se repite con 20 semillas y se reporta el promedio de épocas junto con el porcentaje de corridas que convergieron. En los conjuntos reales se usa una semilla y se reporta la exactitud en entrenamiento y en prueba, las épocas y si convergió. Los valores de α explorados son $\{0,01, 0,05, 0,1, 0,3, 0,5, 1\}$ para el perceptrón y $\{0,001, 0,01, 0,05, 0,1, 0,2, 0,5, 1\}$ para el Adaline en compuertas, con rangos más bajos en billetes por la escala de las entradas. El tope de épocas es 100 en compuertas para el perceptrón, 1000 para el Adaline, y 200 y 500 respectivamente en los conjuntos reales.




Figura 1. Fronteras de decisión aprendidas por el perceptrón para AND y OR de dos entradas (regla 3, $\alpha = 0,1$, $\theta = 0$).




Figura 2. Épocas promedio hasta convergencia del perceptrón (regla 3) en función de α para AND y OR de 2, 3 y 4 entradas, 20 semillas.

Tabla II

PERCEPTRÓN: ÉPOCAS PROMEDIO (MÍNIMO-MÁXIMO) HASTA CONVERGENCIA CON LAS TRES REGLAS, 20 SEMILLAS, $\alpha = 0,1$, $\theta = 0$, SALIDA EN $\{-1, 1\}$. CONVERGIÓ EL 100 % DE LAS CORRIDAS EN TODOS LOS CASOS.

Compuerta	n	Regla 1	Regla 2	Regla 3
AND	2	4,6 (2–8)	4,8 (2–6)	4,9 (2–7)
AND	3	7,8 (2–15)	8,0 (2–18)	7,4 (2–14)
AND	4	17,5 (4–31)	18,0 (7–31)	14,0 (3–34)
OR	2	3,0 (2–4)	4,0 (4–4)	4,6 (2–6)
OR	3	3,7 (2–5)	5,0 (5–5)	4,0 (2–6)
OR	4	4,2 (2–6)	6,0 (6–6)	4,2 (2–6)

IV. RESULTADOS

IV-A. Perceptrón en compuertas

La Fig. 1 muestra las fronteras aprendidas para AND y OR de dos entradas con la regla (5), $\alpha = 0,1$ y semilla 1. El perceptrón converge en 2 épocas en ambos casos. La Tabla II resume el comportamiento de las tres reglas en las seis compuertas con 20 semillas: todas convergen el 100 % de las veces y el número de épocas crece con el número de entradas, sobre todo en la AND, que con 4 entradas necesita entre 14 y 18 épocas en promedio frente a 4 o 6 de la OR. Entre reglas no hay diferencias grandes cuando la salida se codifica en $\{-1, 1\}$; la regla (5) es ligeramente mejor en la AND de 4 entradas (14,0 contra 17,5 y 18,0).

El efecto del factor de aprendizaje se muestra en la Fig. 2 y la Tabla III. Con $\alpha = 0,01$ el perceptrón necesita entre 18 y 28 épocas porque cada corrección es muy pequeña frente a los pesos iniciales, que están en $[0, 1]$. A partir de $\alpha = 0,1$ las épocas se estabilizan y ya no bajan más; con $\alpha = 1$ incluso suben un poco en la OR. En el perceptrón no hay divergencia con α grande, porque la corrección solo se aplica cuando hay error y siempre en la dirección correcta.

El umbral θ también influye. Para las compuertas de dos entradas, con $\theta = -1$ la AND tarda 8,0 épocas y la OR 9,6; con $\theta = 0$ tardan 4,9 y 4,6; con $\theta = 1$ tardan 2,8 y 2,0. Como los pesos iniciales son positivos, un umbral positivo deja de entrada la neurona apagada para los patrones con pocas entradas activas, que es lo que tanto la AND como la OR

Tabla III

PERCEPTRÓN, REGLA 3: ÉPOCAS PROMEDIO SEGÚN α , 20 SEMILLAS. TODAS LAS CORRIDAS CONVERGIERON.

	n	0,01	0,05	0,1	0,3	0,5	1
AND	2	24,2	6,9	4,9	5,3	4,6	4,8
AND	3	18,0	7,8	7,4	9,1	7,8	8,0
AND	4	20,9	14,3	14,0	15,4	17,5	18,0
OR	2	27,8	6,9	4,6	3,1	3,0	4,0
OR	3	23,9	6,4	4,0	3,5	3,7	5,0
OR	4	24,1	6,3	4,2	3,7	4,2	6,0

Tabla IV

PERCEPTRÓN DE DOS ENTRADAS: EFECTO DE LA CODIFICACIÓN DE LA SALIDA, 20 SEMILLAS, $\alpha = 0,1$.

Salida	Compuerta	Regla	Épocas prom.	Convergió
$\{-1, 1\}$	AND	1	4,6	100 %
$\{-1, 1\}$	AND	2	4,8	100 %
$\{-1, 1\}$	AND	3	4,9	100 %
$\{-1, 1\}$	OR	1	3,0	100 %
$\{-1, 1\}$	OR	2	4,0	100 %
$\{-1, 1\}$	OR	3	4,6	100 %
$\{0, 1\}$	AND	1	100	0 %
$\{0, 1\}$	AND	2	4,6	100 %
$\{0, 1\}$	AND	3	6,9	100 %
$\{0, 1\}$	OR	1	100	0 %
$\{0, 1\}$	OR	2	3,0	100 %
$\{0, 1\}$	OR	3	6,9	100 %

necesitan para la mayoría de sus filas, y por eso hay menos que corregir.

La codificación de la salida resultó ser el parámetro con el efecto más drástico, y se muestra en la Tabla IV. Con salida en $\{-1, 1\}$ las tres reglas convergen. Con salida en $\{0, 1\}$ las reglas (4) y (5) siguen convergiendo, pero la regla (3) no converge nunca en 100 épocas. La razón es directa: cuando la salida deseada es 0, $\Delta W_i = d(x)X_i = 0$, así que la neurona no recibe ninguna corrección de los patrones que deberían dar salida baja y solo aprende a activarse. Con $\{-1, 1\}$ esos patrones sí empujan los pesos en dirección negativa.

Tabla V
PERCEPTRÓN EN IRIS: PROMEDIO SOBRE $\alpha \in \{0,01, 0,05, 0,1, 0,5, 1\}$.
EXACTITUD EN %.

Problema	Partición	Épocas	Entren.	Prueba
A	60-40	6,0	100,0	100,0
A	70-30	5,6	100,0	100,0
A	80-20	6,0	100,0	100,0
A	90-10	6,0	100,0	100,0
B	60-40	125,6	97,9	92,7
B	70-30	200,0	98,5	89,4
B	80-20	175,0	98,5	91,4
B	90-10	200,0	95,4	100,0




Figura 3. Problema B de Iris en el plano largo y ancho del pétalo, partición 60-40. Las clases se traslapan y el perceptrón no converge.

IV-B. Perceptrón en Iris

La Tabla V resume las cuatro particiones promediando sobre los cinco valores de α . En el problema A, *setosa* contra el resto, el perceptrón converge siempre y clasifica el 100 % tanto en entrenamiento como en prueba en las cuatro particiones; el único efecto de α es la velocidad, de 15 a 17 épocas con $\alpha = 0,01$ a 2 épocas con $\alpha \geq 0,5$. En el problema B el perceptrón casi nunca converge y agota las 200 épocas, con exactitud en entrenamiento entre 94,6 y 98,7 % y en prueba entre 87,5 y 100 %. La Fig. 3 muestra por qué: en el plano largo y ancho del pétalo las dos clases se traslapan y ninguna recta las separa. Hubo tres casos en los que sí convergió en el conjunto de entrenamiento, por ejemplo la partición 60-40 con $\alpha = 0,1$ en 17 épocas con 100 % de acierto en entrenamiento, lo que indica que ese subconjunto particular sí era separable; en prueba, sin embargo, dio 93,2 %, igual que los casos que no convergieron. El 100 % de la partición 90-10 corresponde a un conjunto de prueba de solo 10 flores y no debe leerse como una mejora real.

IV-C. Perceptrón en billetes

Con los cuatro atributos de la transformada *wavelet* el perceptrón no converge en 200 épocas en ninguna de las 40 corridas, lo que indica que las dos clases no son perfectamente separables, pero la exactitud es alta y estable: entre 97,1

Tabla VI
PERCEPTRÓN EN BILLETES: PROMEDIO SOBRE
 $\alpha \in \{0,01, 0,05, 0,1, 0,5, 1\}$. NINGUNA CORRIDA CONVERGIÓ EN 200
ÉPOCAS. EXACTITUD EN %.

Escalado	Partición	Entren.	Prueba
no	60-40	98,9	99,2
no	70-30	98,6	98,6
no	80-20	98,7	98,4
no	90-10	98,8	98,4
sí	60-40	98,6	98,1
sí	70-30	98,9	98,4
sí	80-20	98,9	98,5
sí	90-10	98,5	97,7




Figura 4. Perceptrón en billetes: exactitud en prueba contra α para las cuatro particiones, sin escalar y con escalado min-max.

y 99,3 % en prueba. La Tabla VI resume por partición y escalado. El escalado al rango $[0, 1]$ no ayuda al perceptrón, y de hecho la mejor exactitud, 99,3 % en la partición 60-40 con $\alpha = 0,05$, se obtiene sin escalar. Esto es coherente con el modelo: el escalón solo mira el signo de la suma ponderada, así que la escala de las entradas se compensa con la escala de los pesos. La Fig. 4 muestra las curvas de exactitud contra α . En el mejor caso, de 549 billetes de prueba el perceptrón se equivoca en 4.

IV-D. Adaline en compuertas

La Fig. 5 muestra el Adaline en la OR de dos entradas con $\alpha = 0,05$. La salida lineal para los cuatro patrones queda en 0,26, 0,75, 0,73 y 1,23, y el escalón en 0,5 los clasifica todos bien. El *EC* baja de forma monótona y se estanca en 0,1385 después de 104 épocas: ese es el mínimo del error cuadrático de una recta ajustada a esa tabla de verdad, y no es cero porque los cuatro puntos no están sobre un plano. Aquí se ve la diferencia de fondo con el perceptrón, que para en cuanto clasifica bien: el Adaline sigue afinando la salida lineal aunque la clasificación ya sea correcta.

La Tabla VII resume las siete compuertas con los mismos parámetros. En todas el entrenamiento se detiene por la tolerancia de cambio entre 53 y 128 épocas. La exactitud es 100 % en AND y OR de 2 y 3 entradas, pero en la AND de 4 entradas clasifica mal un patrón de 16 (93,75 %) y en la OR de 3 entradas un patrón de 8 (87,5 %). Esto no es un error de implementación sino una propiedad del modelo: la regla delta minimiza el error cuadrático de la salida lineal, y




Figura 5. Adaline en la OR de dos entradas ($\alpha = 0,05$): frontera aprendida y error cuadrático por época.

Tabla VII
ADALINE EN COMPUERTAS: $\alpha = 0,05$, TOLERANCIA 10^{-6} , UMBRAL 0,5, SEMILLA 1.

Compuerta	n	Épocas	EC final	Exactitud
AND	2	67	0,138	100 %
AND	3	115	0,295	100 %
AND	4	59	0,429	93,75 %
OR	2	104	0,139	100 %
OR	3	53	0,273	87,5 %
OR	4	86	0,370	93,75 %
XOR	2	128	0,554	25 %

el plano que minimiza ese error no es necesariamente el que separa las clases. Al aumentar el número de entradas la tabla de verdad tiene más esquinas y la recta de mínimos cuadrados queda más lejos de algunas de ellas. Con $\alpha = 0,1$ la AND de 4 sí alcanza el 100 %, lo que muestra que la solución a la que se llega también depende del camino. La XOR, como se esperaba, no se resuelve: el EC se estanca en 0,554 y la exactitud es 25 %.

El factor de aprendizaje tiene en el Adaline un comportamiento muy distinto al del perceptrón, y se resume en la Tabla VIII y en la Fig. 6. Con $\alpha = 0,001$ el error baja tan despacio que no se estanca en 1000 épocas. Entre 0,01 y 0,2 el número de épocas cae de unas 300 a unas 40 y el EC final se mantiene cerca del mínimo. Con $\alpha = 0,5$ el algoritmo para rápido pero en un EC mayor, por ejemplo 0,5 en la AND de 2 y 1,81 en la AND de 4, y la exactitud cae a 75 y 56 %; y con $\alpha = 1$ el error diverge, llegando a 5×10^5 en dos entradas y a infinito en tres y cuatro. Es el límite de estabilidad del descenso de gradiente: con un paso demasiado grande cada corrección sobrepasa el mínimo y el error crece.

La tolerancia de parada y el umbral del escalón se exploraron en la AND de dos entradas. Con tolerancia 10^{-2} el entrenamiento para en 6 épocas con $EC = 0,162$, con 10^{-4} en 34 épocas con $EC = 0,139$ y con 10^{-6} en 67 épocas con $EC = 0,1385$, que ya es el mínimo. La exactitud es 100 % con umbral 0,5 y 0,7 en todos los casos; con umbral 0,3 y tolerancia gruesa (10^{-2} o 10^{-3}) baja a 75 %, porque la salida lineal del patrón (0,1) todavía está por encima de 0,3 cuando el entrenamiento se detiene temprano.

Tabla VIII
ADALINE: ÉPOCAS HASTA QUE EL EC DEJA DE BAJAR, EC FINAL Y EXACTITUD SEGÚN α , PARA AND Y OR DE 2 Y 4 ENTRADAS.

	0,001	0,01	0,05	0,1	0,2	0,5	1
AND 2							
Épocas	1000	327	67	27	47	20	1000
EC	0,129	0,128	0,138	0,154	0,195	0,500	$5 \cdot 10^5$
Exact.	100	100	100	100	100	75	50
AND 4							
Épocas	1000	186	59	42	35	30	96
EC	0,346	0,359	0,429	0,531	0,762	1,807	∞
Exact.	93,8	93,8	93,8	100	81,3	56,3	6,3
OR 2							
Épocas	1000	435	104	49	20	19	1000
EC	0,133	0,128	0,139	0,154	0,195	0,500	$5 \cdot 10^5$
Exact.	100	100	100	100	100	75	0
OR 4							
Épocas	1000	237	86	51	34	23	96
EC	0,356	0,349	0,370	0,394	0,435	0,655	∞
Exact.	93,8	93,8	93,8	93,8	93,8	93,8	6,3




Figura 6. Adaline: épocas hasta estancarse según α (izquierda) y curva del EC en la OR de 4 entradas para cuatro valores de α (derecha).

Tabla IX
PERCEPTRÓN (REGLA 3) CONTRA ADALINE EN COMPUERTAS, $\alpha = 0,05$, SALIDA $\{0,1\}$, UMBRAL 0,5, SEMILLA 1.


Compuerta	n	Perceptrón		Adaline	
		Épocas	Exact.	Épocas	Exact.
AND	2	4	100	67	100
AND	3	7	100	115	100
AND	4	6	100	59	93,75
OR	2	2	100	104	100
OR	3	3	100	53	87,5
OR	4	5	100	86	93,75
XOR	2	1000	50	128	25

La Tabla IX compara los dos modelos en las mismas compuertas, con $\alpha = 0,05$, salida en $\{0,1\}$ y umbral 0,5. El perceptrón converge en 2 a 7 épocas con 100 % en todas las compuertas separables; el Adaline gasta entre 53 y 115 épocas y en dos casos deja patrones mal clasificados. En la XOR ninguno de los dos funciona.

Tabla X

ADALINE EN IRIS: PROMEDIO SOBRE CINCO VALORES DE α . EXACTITUD EN %.

Problema	Partición	Épocas	EC final	Entren.	Prueba
A	60-40	467	0,97	100,0	100,0
A	70-30	451	1,13	100,0	100,0
A	80-20	446	1,32	100,0	100,0
A	90-10	431	1,49	100,0	100,0
B	60-40	398	1,46	98,2	93,6
B	70-30	381	1,73	98,5	90,6
B	80-20	353	2,40	98,0	94,3
B	90-10	359	2,67	97,0	100,0

Figura 7. Adaline en Iris, partición 60-40 y $\alpha = 0,01$: error cuadrático por época en los dos problemas.

IV-E. Adaline en Iris

La Tabla X resume los resultados con $\alpha \in \{0,001, 0,005, 0,01, 0,05, 0,1\}$. En el problema A el Adaline clasifica el 100 % en entrenamiento y prueba en las cuatro particiones, igual que el perceptrón, pero necesita cientos de épocas porque sigue reduciendo el EC mucho después de que la clasificación ya es correcta; con los α más pequeños ni siquiera se estanca en las 500 épocas de tope. En el problema B la exactitud en prueba va de 90,6 a 100 %, muy parecida a la del perceptrón, con la diferencia de que el Adaline sí se detiene de forma ordenada cuando el EC deja de bajar, mientras que el perceptrón agotaba el tope de épocas sin converger. La Fig. 7 muestra las dos curvas de error: en A el EC baja hasta cerca de 1,0 y en B se queda en 1,4, que es el reflejo del traslape entre clases.



IV-F. Adaline en billetes

Aquí el escalado pasa de ser irrelevante a ser decisivo, y la Tabla XI lo muestra. Sin escalar, con $\alpha = 0,05$ el error se dispara a infinito en una o dos épocas en las cuatro particiones y la exactitud cae al nivel del azar, entre 34 y 62 %; con $\alpha = 0,01$ el error ya no diverge pero queda alto y la exactitud baja a 92–97 %; solo con $\alpha \leq 0,001$ se obtienen resultados buenos, de 96,1 a 97,5 %. La causa es la curtosis, que llega a 17,9: en la regla delta la corrección es proporcional a la entrada, y una entrada grande multiplica el paso efectivo. Con las entradas escaladas a $[0, 1]$ todo α entre 0,001 y 0,05 da

Tabla XI

ADALINE EN BILLETES: EXACTITUD EN PRUEBA (%) POR PARTICIÓN Y α , SIN ESCALAR Y CON ESCALADO MIN-MAX. SE MARCA CON ∞ LA DIVERGENCIA DEL EC .

Escalado	Partición	10^{-4}	10^{-3}	$5 \cdot 10^{-3}$	10^{-2}	$5 \cdot 10^{-2}$
no	60-40	96,7	97,5	96,5	94,0	36,1 (∞)
no	70-30	96,1	96,4	97,1	97,3	44,4 (∞)
no	80-20	97,4	97,4	96,4	92,3	34,3 (∞)
no	90-10	96,4	96,4	96,4	94,9	62,0 (∞)
sí	60-40	88,9	96,9	96,5	96,5	96,4
sí	70-30	90,8	96,1	96,1	96,1	95,9
sí	80-20	91,6	97,4	97,8	97,8	97,4
sí	90-10	93,4	96,4	96,4	96,4	96,4

Figura 8. Adaline en billetes: exactitud en prueba contra α , sin escalar (izquierda) y con escalado (derecha). Sin escalar, $\alpha = 0,05$ diverge.Figura 9. Mejor Adaline en billetes (80-20, escalado, $\alpha = 0,005$): curva del EC y matriz de confusión en prueba.

entre 95,9 y 97,8 %, y solo $\alpha = 10^{-4}$ es demasiado lento y se queda en 89–93 % al agotar las 500 épocas. La Fig. 8 muestra las dos situaciones y la Fig. 9 el mejor caso, la partición 80-20 escalada con $\alpha = 0,005$, que llega a 97,8 % en prueba con 287 épocas.

La Tabla XII cierra la comparación entre los dos modelos sobre la partición 80-20 escalada. El perceptrón obtiene entre 97,4 y 98,9 % pero nunca converge, y agota las 500 épocas para todo α ; el Adaline obtiene entre 97,4 y 97,8 % y se detiene entre 26 y 154 épocas para $\alpha \geq 0,01$. Es decir, el perceptrón clasifica un poco mejor y el Adaline termina de forma predecible.

Tabla XII
PERCEPTRÓN CONTRA ADALINE EN BILLETES, PARTICIÓN 80-20
ESCALADA, SALIDA $\{0, 1\}$, UMBRAL 0,5. EXACTITUD EN PRUEBA EN %.

α	Perceptrón		Adaline	
	Épocas	Exact.	Épocas	Exact.
0,001	500	98,9	500	97,4
0,01	500	98,9	154	97,8
0,05	500	98,9	46	97,4
0,1	500	97,4	26	97,4

V. DISCUSIÓN

Varias cosas salieron distintas de lo que se esperaba al empezar, y son las que más enseñan.

La primera es que la regla $\Delta W_i = d(x)X_i$ funciona o no dependiendo de un detalle que parece cosmético, la codificación de la salida. Con $\{-1, 1\}$ converge tan bien como las otras dos; con $\{0, 1\}$ no converge nunca. No es un problema numérico sino algebraico: multiplicar por $d(x) = 0$ elimina la corrección. Las reglas que usan la diferencia $d(x) - Y(x)$ no tienen ese problema porque la diferencia es distinta de cero siempre que hay error, sea cual sea la codificación.

La segunda es que el factor de aprendizaje juega papeles opuestos en los dos modelos. En el perceptrón un α grande no hace daño, porque cada corrección empuja los pesos en la dirección correcta y la única consecuencia es que el hiperplano final queda en otro sitio; el costo de un α pequeño es solo más épocas. En el Adaline, en cambio, α tiene un límite de estabilidad por encima del cual el error diverge, y ese límite depende de la magnitud de las entradas. Por eso el escalado, que al perceptrón no le cambia nada, es lo que hace que el Adaline funcione en billetes.

La tercera es que el Adaline puede clasificar mal patrones que el perceptrón clasifica bien, como pasó en la AND de 4 y la OR de 3 entradas. Minimizar el error cuadrático de la salida lineal no es lo mismo que minimizar el error de clasificación: el plano de mínimos cuadrados es el mejor compromiso para todos los patrones a la vez, y ese compromiso puede dejar una esquina de la tabla de verdad del lado equivocado del umbral. A cambio, el Adaline entrega una salida graduada, sigue aprendiendo cuando el problema no es separable y se detiene de forma ordenada, cosas que el perceptrón no ofrece.

La cuarta es sobre las particiones. Entre 60-40 y 90-10 las diferencias de exactitud son de uno o dos puntos y no tienen una dirección consistente. Lo que sí cambia es la confiabilidad del número: el 100 % de prueba del problema B de Iris en la partición 90-10 sale de 10 flores, y con 10 flores un solo error habría dado 90 %. Las particiones con más datos de prueba dan estimaciones más estables aunque el modelo entrene con menos.

Como limitaciones, los resultados en los conjuntos reales usan una sola semilla, así que diferencias menores a un punto porcentual no deberían interpretarse. Tampoco se ajustó el umbral θ en los conjuntos reales, que en el Adaline podría

recuperar algo de exactitud, y no se probó la normalización por puntuación z como alternativa al escalado min-max.

VI. CONCLUSIONES

Se implementaron el perceptrón simple y el Adaline como funciones de MATLAB completamente parametrizables y se evaluaron sobre compuertas lógicas y dos conjuntos de datos reales en cuatro proporciones de partición, cubriendo los doce puntos del taller.

El perceptrón con cualquiera de las tres reglas resuelve AND y OR de 2, 3 y 4 entradas en menos de 20 épocas en promedio, siempre que la salida se codifique en $\{-1, 1\}$; con $\{0, 1\}$ la primera regla queda inutilizada. En Iris separa *setosa* con 100 % y en billetes llega a 99,3 % sin escalar las entradas, aunque nunca converge porque las clases no son perfectamente separables.

El Adaline resuelve las mismas compuertas en 53 a 128 épocas con la tolerancia de cambio del *EC* como criterio de parada, con 100 % de exactitud salvo en la AND de 4 y la OR de 3 entradas, donde la solución de mínimos cuadrados deja un patrón mal clasificado. En Iris iguala al perceptrón y en billetes llega a 97,8 %, pero solo con las entradas escaladas: sin escalar diverge para $\alpha \geq 0,05$.

Ninguno de los dos modelos resuelve la XOR, como establece la teoría. El factor de aprendizaje, el umbral, la codificación de la salida y el escalado de las entradas no son detalles secundarios: cada uno cambió el resultado de algún experimento de forma cualitativa, y el taller sirvió precisamente para ver dónde y por qué.

REFERENCIAS

- [1] F. Rosenblatt, "The perceptron: A probabilistic model for information storage and organization in the brain," *Psychological Review*, vol. 65, no. 6, pp. 386–408, 1958.
- [2] B. Widrow and M. E. Hoff, "Adaptive switching circuits," in *1960 IRE WESCON Convention Record, Part 4*, New York, 1960, pp. 96–104.
- [3] The MathWorks, Inc., "MATLAB version 26.1 (R2026a)," Natick, Massachusetts, 2026.
- [4] S. Haykin, *Neural Networks and Learning Machines*, 3rd ed. Upper Saddle River, NJ: Pearson, 2009.
- [5] M. Minsky and S. Papert, *Perceptrons: An Introduction to Computational Geometry*. Cambridge, MA: MIT Press, 1969.
- [6] R. A. Fisher, "The use of multiple measurements in taxonomic problems," *Annals of Eugenics*, vol. 7, no. 2, pp. 179–188, 1936.
- [7] V. Lohweg, "Banknote authentication," UCI Machine Learning Repository, 2013, <https://doi.org/10.24432/C55P57>.