

Perceptrón simple y Adaline. Implementación parametrizable en MATLAB y evaluación sobre compuertas lógicas, Iris y autenticación de billetes

Sergio Duarte

Maestría, Inteligencia Computacional Aplicada
sergioduartedev@gmail.com

Resumen—Este trabajo implementa en MATLAB una red de una sola neurona y una sola capa con dos modelos clásicos, el perceptrón simple con tres reglas de corrección de pesos seleccionables y el Adaline con la regla delta sobre la salida lineal. Ambas implementaciones son parametrizables en número de entradas, umbral, factor de aprendizaje, codificación de la salida y criterio de parada. Los modelos se evalúan sobre compuertas AND y OR de 2, 3 y 4 entradas, midiendo el número de épocas hasta la convergencia sobre 20 inicializaciones aleatorias, y sobre los conjuntos Iris y *Banknote Authentication* particionados en proporciones 60-40, 70-30, 80-20 y 90-10. Con un factor de aprendizaje de 0,1 el perceptrón converge en todas las compuertas en menos de 20 épocas en promedio, alcanza 100 % de exactitud en el problema separable de Iris y llega a 99,3 % en billetes. El Adaline clasifica correctamente la mayoría de las compuertas, aunque al minimizar el error cuadrático de la salida lineal en lugar del error de clasificación deja un patrón mal clasificado en la AND de 4 entradas y en las OR de 3 y 4 entradas, y en billetes alcanza 97,8 % con las entradas escaladas, mientras que sin escalar el error diverge para un factor de aprendizaje de 0,05. Se documenta además el efecto de la codificación de la salida, que anula la primera regla de aprendizaje cuando se emplea $\{0, 1\}$, y la incapacidad de ambos modelos para representar la XOR.

Index Terms—perceptrón, Adaline, regla delta, compuertas lógicas, separabilidad lineal, MATLAB

I. INTRODUCCIÓN

El perceptrón de Rosenblatt [1] y el Adaline de Widrow y Hoff [2] son los dos modelos de neurona artificial más antiguos que continúan presentes en la enseñanza de redes neuronales, porque con una sola neurona ya intervienen los elementos que después se reutilizan en arquitecturas mayores, entre ellos los pesos, el umbral, la función de activación, la regla de aprendizaje, el factor de aprendizaje, las épocas y el criterio de parada [3]. La diferencia entre ambos modelos es pequeña en la formulación y determinante en el comportamiento. El perceptrón corrige los pesos a partir del error de la salida binaria y actúa únicamente cuando la clasificación es incorrecta, mientras que el Adaline corrige a partir del error de la salida lineal y continúa ajustando aunque la clasificación ya sea correcta.

Este documento corresponde al Taller 1 de la asignatura Inteligencia Computacional Aplicada. Las secciones III y IV cubren los puntos 1 a 6 del taller en las subsecciones dedicadas al perceptrón y los puntos 7 a 12 en las dedicadas al Adaline.

II. MARCO TEÓRICO

II-A. Perceptrón simple

La neurona recibe n entradas $x_1, \dots, x_n$ y una entrada constante igual a 1 cuyo peso w_0 hace de sesgo. La suma ponderada es

$$z = w_0 + \sum_{i=1}^n w_i x_i, \quad (1)$$

y la salida se obtiene aplicando una función escalón respecto de un umbral θ , tal como expresa la ecuación siguiente.

$$Y(x) = \begin{cases} y_{\max} & \text{si } z > \theta \\ y_{\min} & \text{en otro caso} \end{cases} \quad (2)$$

Aquí $\{y_{\min}, y_{\max}\}$ es la codificación elegida para la salida, típicamente $\{-1, 1\}$ o $\{0, 1\}$.

El taller solicita que el script permita elegir entre las tres formas de corrección de los pesos que definen las ecuaciones (3) a (5).

$$\Delta W_i = d(x) X_i \quad (3)$$

$$\Delta W_i = [d(x) - Y(x)] X_i \quad (4)$$

$$\Delta W_i = \alpha [d(x) - Y(x)] X_i \quad (5)$$

En ellas $d(x)$ es la salida deseada, $Y(x)$ la generada y α el factor relativo de aprendizaje, y el ajuste siempre es $W_i^* = W_i + \Delta W_i$. La regla (3) es de tipo hebbiano, se aplica solo cuando hay error y no utiliza la salida del modelo. La regla (4) corresponde a la formulación original del perceptrón con $\alpha = 1$ y la regla (5) es la misma con factor de aprendizaje explícito. El teorema de convergencia del perceptrón garantiza que, si las clases son linealmente separables, la regla (5) encuentra un hiperplano separador en un número finito de correcciones [4]. Las compuertas AND y OR de cualquier número de entradas son linealmente separables, mientras que la XOR no lo es [5].

II-B. Adaline y regla delta

El Adaline usa la misma suma ponderada, pero el error se calcula sobre la salida lineal $y = z$ y no sobre la salida del escalón. La regla delta minimiza el error cuadrático mediante descenso de gradiente.

$$\Delta W_i = \alpha [d(x) - y] X_i, \quad \Delta \theta = \alpha [d(x) - y] \quad (6)$$

El entrenamiento se detiene cuando el error cuadrático de la época

$$EC = \frac{1}{2} \sum_{k=1}^Q \varepsilon_k^2, \quad \varepsilon_k = d^{(k)} - y^{(k)} \quad (7)$$

baja de un valor permitido, con Q el número de patrones. Para clasificar, la salida lineal se pasa por un escalón con umbral θ , en este trabajo $\theta = 0,5$ para salidas en $\{0,1\}$. Como la regla delta es un descenso de gradiente, el factor α tiene un límite de estabilidad, de modo que un valor superior a ese límite hace que el error aumente en lugar de disminuir [4]. En Iris, la clase *setosa* es separable de las otras dos, mientras que *versicolor* y *virginica* se traslapan [6]. Estas propiedades se usan como casos de prueba positivos y negativos.

III. METODOLOGÍA

III-A. Implementación

Se escribieron dos funciones en MATLAB R2026a [7], `perceptron.m` y `adaline.m`, con la misma interfaz. Ambas reciben la matriz de patrones X de tamaño $N \times n$, el vector de salidas deseadas d y una estructura de opciones con el número de entradas implícito en X , la regla de corrección en el caso del perceptrón, el factor α , el umbral θ , la codificación de la salida, el tope de épocas y la semilla de los pesos iniciales. Cada función devuelve los pesos, el sesgo y una estructura con el histórico de la ejecución. El sesgo se implementa como el peso w_0 de una entrada constante 1, que es el modelo de la figura del taller. Los pesos iniciales se toman de una distribución uniforme en $[0, 1]$ a partir de una semilla, para que cualquier ejecución sea reproducible. Una función auxiliar `predecir.m` aplica la suma ponderada y el escalón, y sirve igual para los dos modelos.

En los dos modelos los patrones se presentan en el orden fijo del conjunto de entrenamiento y los pesos se corrigen tras cada patrón. En el perceptrón una época es una pasada por todos los patrones, y se declara convergencia cuando una época completa no requiere ninguna corrección, lo que equivale al contador `aux` del código de clase. En el Adaline, al final de cada época se calcula (7). Se incorporó un segundo criterio de parada además del error mínimo, porque con una tabla de verdad la salida lineal no coincide de forma exacta con los ceros y unos deseados, el EC se estabiliza en un valor positivo y el entrenamiento no terminaría con el error mínimo como único criterio. Por esa razón el entrenamiento también se detiene cuando el cambio del EC entre dos épocas consecutivas cae por debajo de una tolerancia, fijada por defecto en 10^{-6} .

III-B. Conjuntos de datos

Compuertas. La función `compuerta.m` genera la tabla de verdad completa de AND, OR o XOR para n entradas en $\{0,1\}$, con la salida codificada según se pida. Para $n = 2, 3, 4$ hay 4, 8 y 16 patrones. La XOR no forma parte del enunciado y se añade como caso de control negativo.

Iris. Es el conjunto que carga y particiona el script `Dataset_train_test.mlx` entregado en clase, al que se

refieren los puntos 4 y 10 del taller. Contiene 150 flores, cuatro medidas en centímetros y tres especies de 50 ejemplares cada una [6]. Como la red tiene una sola neurona, se definen dos problemas binarios. El problema A enfrenta *setosa* contra las otras dos especies y es linealmente separable, y el problema B enfrenta *versicolor* contra *virginica* y no lo es.

Banknote. 1372 billetes descritos por cuatro estadísticos de la transformada *wavelet* de su imagen, que son la varianza, la asimetría, la curtosis y la entropía. La clase indica si el billete es auténtico, con 762 casos, o falso, con 610 [8]. Las cuatro variables están en escalas distintas, ya que la curtosis va de $-5,3$ a $17,9$ mientras la entropía va de $-8,5$ a $2,4$.

III-C. Particiones

Siguiendo el script `Dataset_train_test` de clase, cada conjunto se mezcla una sola vez con `randperm` y semilla fija, y se corta en las proporciones 60-40, 70-30, 80-20 y 90-10. Para los puntos 5 y 11 el script se modificó de modo que lea `data_banknote_authentication.txt` con `load`, separe las cuatro primeras columnas como atributos y la quinta como clase, y genere las mismas cuatro particiones, que se guardan en un archivo `.mat` para los scripts de modelado. La única otra modificación fue redondear el punto de corte, ya que el producto $0,9 \times 1372 = 1234,8$ no es un índice entero válido. En Iris las particiones tienen 90, 105, 120 y 135 ejemplos de entrenamiento y en billetes 823, 960, 1098 y 1235. Las entradas se escalan al rango $[0, 1]$ con los mínimos y máximos del conjunto de entrenamiento, y esos mismos valores se aplican al de prueba. En billetes se entrena además sin escalar para medir el efecto.

III-D. Protocolo experimental

En compuertas, como el resultado depende de los pesos iniciales, cada combinación de compuerta, número de entradas y parámetro se repite con 20 semillas y se reporta el promedio de épocas junto con el porcentaje de ejecuciones que convergieron. En los conjuntos reales se usa una semilla y se reporta la exactitud, definida como la fracción de patrones clasificados correctamente, en entrenamiento y en prueba, junto con las épocas. Las tablas de los conjuntos reales reportan el promedio sobre los valores de α explorados, mientras que los rangos citados en el texto corresponden a los valores extremos de las ejecuciones individuales.

Los valores del factor de aprendizaje explorados son $\{0,01, 0,05, 0,1, 0,3, 0,5, 1\}$ para el perceptrón en compuertas y $\{0,01, 0,05, 0,1, 0,5, 1\}$ en los conjuntos reales. Para el Adaline son $\{0,001, 0,01, 0,05, 0,1, 0,2, 0,5, 1\}$ en compuertas, $\{0,001, 0,005, 0,01, 0,05, 0,1\}$ en Iris y $\{10^{-4}, 10^{-3}, 5 \times 10^{-3}, 10^{-2}, 5 \times 10^{-2}\}$ en billetes, con valores menores en este último conjunto por la magnitud de las entradas sin escalar. Los rangos cubren dos órdenes de magnitud alrededor de los valores usados en clase. El tope de épocas es 100 en compuertas para el perceptrón y 1000 para el Adaline, y 200 y 500 respectivamente en los conjuntos reales, valores suficientes para que los casos separables converjan con margen.




Figura 1. Fronteras de decisión aprendidas por el perceptrón para AND y OR de dos entradas con la regla 3, $\alpha = 0,1$ y $\theta = 0$.




Figura 2. Épocas promedio hasta convergencia del perceptrón con la regla 3 en función de α para AND y OR de 2, 3 y 4 entradas, 20 semillas.

Tabla I
ÉPOCAS PROMEDIO DEL PERCEPTRÓN CON LA REGLA 3 SEGÚN α , 20 SEMILLAS. TODAS LAS EJECUCIONES CONVERGIERON.

	n	0,01	0,05	0,1	0,3	0,5	1
AND	2	24,2	6,9	4,9	5,3	4,6	4,8
AND	3	18,0	7,8	7,4	9,1	7,8	8,0
AND	4	20,9	14,3	14,0	15,4	17,5	18,0
OR	2	27,8	6,9	4,6	3,1	3,0	4,0
OR	3	23,9	6,4	4,0	3,5	3,7	5,0
OR	4	24,1	6,3	4,2	3,7	4,2	6,0

Tabla II
EFECTO DE LA CODIFICACIÓN DE LA SALIDA EN EL PERCEPTRÓN DE DOS ENTRADAS, 20 SEMILLAS, $\alpha = 0,1$.

Salida	Compuerta	Regla	Épocas prom.	Convergió
$\{-1, 1\}$	AND	1	4,6	100 %
$\{-1, 1\}$	OR	1	3,0	100 %
$\{0, 1\}$	AND	1	100	0 %
$\{0, 1\}$	OR	1	100	0 %
$\{0, 1\}$	AND	3	6,9	100 %
$\{0, 1\}$	OR	3	6,9	100 %

Se entregan las funciones `perceptron.m`, `adaline.m`, `prededir.m` y `compuerta.m`, un *live script* por bloque del taller con las salidas incluidas, y los archivos de particiones generados.

IV. RESULTADOS

IV-A. Perceptrón en compuertas

La Fig. 1 muestra las fronteras aprendidas para AND y OR de dos entradas con la regla (5), $\alpha = 0,1$ y semilla 1. El perceptrón converge en 2 épocas en ambos casos. Con 20 semillas todas las ejecuciones convergen en las seis compuertas con cualquiera de las tres reglas, y el número de épocas crece con el número de entradas, sobre todo en la AND, que con 4 entradas necesita entre 14,0 y 18,0 épocas en promedio frente a 4,2 y 6,0 de la OR. Entre reglas no se observan diferencias apreciables cuando la salida se codifica en $\{-1, 1\}$, con la única excepción de la regla (5) en la AND de 4 entradas, que promedia 14,0 épocas frente a 17,5 y 18,0 de las otras dos.

El efecto del factor de aprendizaje con la regla (5) se muestra en la Fig. 2 y la Tabla I. Con $\alpha = 0,01$ el perceptrón necesita entre 18 y 28 épocas porque cada corrección es muy pequeña frente a los pesos iniciales, que están en $[0, 1]$. A partir de $\alpha = 0,1$ el número de épocas se estabiliza y no disminuye más, y con $\alpha = 1$ aumenta ligeramente en la OR. En el perceptrón no se observa divergencia con valores altos de α , porque la corrección se aplica únicamente cuando hay error y siempre en la dirección que reduce ese error.

El umbral también influye en la velocidad de convergencia. En las compuertas de dos entradas, con $\theta = -1$ la AND

requiere 8,0 épocas y la OR 9,6, con $\theta = 0$ requieren 4,9 y 4,6, y con $\theta = 1$ requieren 2,8 y 2,0. Dado que los pesos iniciales son positivos, un umbral positivo mantiene la neurona inactiva ante los patrones con pocas entradas activas, que corresponden a la salida deseada en la mayoría de las filas de ambas compuertas, y por eso el número de correcciones necesarias disminuye.

La codificación de la salida resultó ser el parámetro con el efecto más marcado, y se muestra en la Tabla II. Con salida en $\{-1, 1\}$ las tres reglas convergen. Con salida en $\{0, 1\}$ las reglas (4) y (5) siguen convergiendo, pero la regla (3) no converge en ninguna de las 20 ejecuciones. La causa es algebraica. Cuando la salida deseada es 0 se obtiene $\Delta W_i = d(x)X_i = 0$, de manera que la neurona no recibe corrección alguna de los patrones que deberían producir salida baja y solo aprende a activarse. Con la codificación $\{-1, 1\}$ esos mismos patrones desplazan los pesos en dirección negativa.

IV-B. Perceptrón en Iris

La Tabla III resume las cuatro particiones promediando sobre los cinco valores de α . En el problema A el perceptrón converge siempre y clasifica el 100 % tanto en entrenamiento como en prueba en las cuatro particiones, y el único efecto de α es la velocidad, de 15 a 17 épocas con $\alpha = 0,01$ a 2 épocas con $\alpha \geq 0,5$. En el problema B el perceptrón casi nunca converge y agota las 200 épocas, con exactitud en entrenamiento entre 94,6 y 98,7 % y en prueba entre 87,5 y 100 % según el valor de α . La Fig. 3 muestra la razón. En el plano largo y ancho del pétalo las dos clases se traslapan y ninguna recta las separa. Hubo tres casos

Tabla III
PERCEPTRÓN EN IRIS, PROMEDIO SOBRE $\alpha \in \{0,01, 0,05, 0,1, 0,5, 1\}$.
EXACTITUD EN %.

Problema	Partición	Épocas	Entren.	Prueba
A	60-40	6,0	100,0	100,0
A	70-30	5,6	100,0	100,0
A	80-20	6,0	100,0	100,0
A	90-10	6,0	100,0	100,0
B	60-40	125,6	97,9	92,7
B	70-30	200,0	98,5	89,4
B	80-20	175,0	98,5	91,4
B	90-10	200,0	95,4	100,0




Figura 3. Problema B de Iris en el plano largo y ancho del pétalo, partición 60-40. Las clases se traslapan y el perceptrón no converge.

en los que sí convergió en el conjunto de entrenamiento, por ejemplo la partición 60-40 con $\alpha = 0,1$ en 17 épocas con 100 % de acierto en entrenamiento, lo que indica que ese subconjunto particular sí era separable. En prueba, sin embargo, dio 93,2 %, igual que los casos que no convergieron. El 100 % de la partición 90-10 corresponde a un conjunto de prueba de solo 10 flores y no debe leerse como una mejora real.

IV-C. Perceptrón en billetes

Con los cuatro atributos de la transformada *wavelet* el perceptrón no converge dentro del tope de épocas en ninguna de las 40 ejecuciones, lo que indica que las dos clases no son perfectamente separables, aunque la exactitud es alta y estable y se sitúa entre 97,1 y 99,3 % en prueba según el valor de α . La Tabla IV resume los promedios por partición y condición de escalado. El escalado al rango $[0, 1]$ no mejora el resultado del perceptrón, y de hecho la mejor exactitud, de 99,3 % en la partición 60-40 con $\alpha = 0,05$, se obtiene sin escalar. Este comportamiento es coherente con el modelo, ya que el escalón depende solo del signo de la suma ponderada y un cambio de escala en las entradas se compensa con un cambio de escala en los pesos [9]. En el mejor caso, de 549 billetes de prueba el perceptrón clasifica mal 4.

Tabla IV
PERCEPTRÓN EN BILLETES, PROMEDIO SOBRE
 $\alpha \in \{0,01, 0,05, 0,1, 0,5, 1\}$. NINGUNA CORRIDA CONVERGIÓ EN 200
ÉPOCAS. EXACTITUD EN %.

Escalado	Partición	Entren.	Prueba
no	60-40	98,9	99,2
no	70-30	98,6	98,6
no	80-20	98,7	98,4
no	90-10	98,8	98,4
sí	60-40	98,6	98,1
sí	70-30	98,9	98,4
sí	80-20	98,9	98,5
sí	90-10	98,5	97,7




Figura 4. Adaline en la OR de dos entradas con $\alpha = 0,05$. Frontera aprendida y error cuadrático por época.

IV-D. Adaline en compuertas

La Fig. 4 muestra el Adaline en la OR de dos entradas con $\alpha = 0,05$. La salida lineal para los cuatro patrones queda en 0,26, 0,75, 0,73 y 1,23, y el escalón situado en 0,5 los clasifica de forma correcta. El *EC* descende de forma monótona y se estabiliza en 0,139 después de 104 épocas, valor que corresponde al mínimo del error cuadrático alcanzable por una función lineal sobre esa tabla de verdad y que no es cero porque los cuatro puntos no se ajustan de forma exacta a un plano. Aquí se aprecia la diferencia esencial con el perceptrón, que se detiene en cuanto la clasificación es correcta, mientras que el Adaline continúa ajustando la salida lineal.

La Tabla V resume las siete compuertas con los mismos parámetros. En todos los casos el entrenamiento se detiene por la tolerancia de cambio entre 53 y 128 épocas. La exactitud es de 100 % en las compuertas AND y OR de 2 entradas y en la AND de 3 entradas, mientras que la AND de 4 entradas y la OR de 4 entradas clasifican mal un patrón de 16 y la OR de 3 entradas clasifica mal uno de 8. Este comportamiento no responde a un defecto de implementación sino a una propiedad del modelo, ya que la regla delta minimiza el error cuadrático de la salida lineal y el hiperplano que minimiza ese error no es necesariamente el que separa las clases [10]. Al aumentar el número de entradas la tabla de verdad tiene más vértices y el hiperplano de mínimos cuadrados queda más alejado de algunos de ellos. Con $\alpha = 0,1$ la AND de 4 entradas sí alcanza el 100 %, lo que muestra que la solución obtenida

Tabla V
ADALINE EN COMPUERTAS CON $\alpha = 0,05$, TOLERANCIA 10^{-6} , UMBRAL 0,5 Y SEMILLA 1.

Compuerta	n	Épocas	EC final	Exactitud
AND	2	67	0,138	100 %
AND	3	115	0,295	100 %
AND	4	59	0,429	93,75 %
OR	2	104	0,139	100 %
OR	3	53	0,273	87,5 %
OR	4	86	0,370	93,75 %
XOR	2	128	0,554	25 %




Figura 5. Adaline. Épocas hasta estabilizarse según α a la izquierda y curva del EC en la OR de 4 entradas para cuatro valores de α a la derecha.

depende también de la trayectoria del descenso. La XOR no se resuelve, el EC se estabiliza en 0,554 y la exactitud es de 25 %. En comparación, el perceptrón con los mismos parámetros converge en 2 a 7 épocas con 100 % en las seis compuertas separables y tampoco resuelve la XOR.

El factor de aprendizaje tiene en el Adaline un comportamiento muy distinto al del perceptrón, y se resume en la Tabla VI y en la Fig. 5. Con $\alpha = 0,001$ el error baja tan despacio que no se estabiliza en 1000 épocas. Entre 0,01 y 0,2 el número de épocas desciende desde un intervalo de 186 a 435 hasta un intervalo de 20 a 47, y el EC final se mantiene próximo al mínimo. Con $\alpha = 0,5$ el entrenamiento se detiene antes pero en un EC mayor, de 0,500 en la AND de 2 entradas y de 1,807 en la AND de 4 entradas, y la exactitud desciende a 75 y 56,3 %. Con $\alpha = 1$ el error diverge, alcanza 5×10^5 en las compuertas de dos entradas y produce desbordamiento numérico en las de cuatro. Este resultado corresponde al límite de estabilidad del descenso de gradiente, en el que un paso demasiado grande sobrepasa el mínimo en cada corrección y el error aumenta [9]. La tolerancia de parada solo cambia el punto en que se detiene el descenso. En la AND de dos entradas, con tolerancia 10^{-2} el entrenamiento se detiene en 6 épocas con $EC = 0,162$ y con 10^{-6} en 67 épocas con $EC = 0,138$, que ya corresponde al mínimo.

IV-E. Adaline en Iris

La Tabla VII resume los resultados con $\alpha \in \{0,001, 0,005, 0,01, 0,05, 0,1\}$. En el problema A el Adaline clasifica el 100 % en entrenamiento y prueba en

Tabla VI
ADALINE EN COMPUERTAS. ÉPOCAS HASTA QUE EL EC DEJA DE BAJAR, EC FINAL Y EXACTITUD EN % SEGÚN α , PARA AND Y OR DE 2 Y 4 ENTRADAS.

	0,001	0,01	0,05	0,1	0,2	0,5	1
AND 2							
Épocas	1000	327	67	27	47	20	1000
EC	0,129	0,128	0,138	0,154	0,195	0,500	5×10^5
Exact.	100	100	100	100	100	75	50
AND 4							
Épocas	1000	186	59	42	35	30	96
EC	0,346	0,359	0,429	0,531	0,762	1,807	∞
Exact.	93,8	93,8	93,8	100	81,3	56,3	6,3
OR 2							
Épocas	1000	435	104	49	20	19	1000
EC	0,133	0,128	0,139	0,154	0,195	0,500	5×10^5
Exact.	100	100	100	100	100	75	0
OR 4							
Épocas	1000	237	86	51	34	23	96
EC	0,356	0,349	0,370	0,394	0,435	0,655	∞
Exact.	93,8	93,8	93,8	93,8	93,8	93,8	6,3

Tabla VII
ADALINE EN IRIS, PROMEDIO SOBRE CINCO VALORES DE α . EXACTITUD EN %.

Problema	Partición	Épocas	EC final	Entren.	Prueba
A	60-40	467	0,97	100,0	100,0
A	70-30	451	1,13	100,0	100,0
A	80-20	446	1,32	100,0	100,0
A	90-10	431	1,49	100,0	100,0
B	60-40	398	1,46	98,2	93,6
B	70-30	381	1,73	98,5	90,6
B	80-20	353	2,40	98,0	94,3
B	90-10	359	2,67	97,0	100,0

las cuatro particiones, igual que el perceptrón, pero necesita cientos de épocas porque sigue reduciendo el EC mucho después de que la clasificación ya es correcta, y con los α más pequeños no llega a estabilizarse en las 500 épocas de tope. En el problema B la exactitud en prueba va de 90,6 a 100 %, muy parecida a la del perceptrón, con la diferencia de que el Adaline sí se detiene con un criterio explícito cuando el EC deja de bajar, mientras que el perceptrón agotaba el tope de épocas sin converger. En la partición 60-40 con $\alpha = 0,01$ el EC desciende hasta 0,95 en el problema A y se estabiliza en 1,36 en el problema B, valor que refleja el traslape entre clases.

IV-F. Adaline en billetes

En este conjunto el escalado pasa de ser irrelevante a ser determinante, como muestra la Tabla VIII. Sin escalar, con $\alpha = 0,05$ el error diverge en una o dos épocas en las cuatro particiones y la exactitud desciende al nivel del azar, entre 34,3 y 62,0 %. Con $\alpha = 0,01$ el error ya no diverge pero permanece alto y la exactitud queda entre 92,3 y 97,3 %, y solo con valores iguales o inferiores a 0,001 se obtienen resultados entre 96,1 y 97,5 %. La causa es la magnitud de la curtosis,

Tabla VIII
ADALINE EN BILLETES. EXACTITUD EN PRUEBA EN % POR PARTICIÓN Y α , SIN ESCALAR Y CON ESCALADO MIN-MAX. SE MARCA CON ∞ LA DIVERGENCIA DEL EC .

Escalado	Partición	10^{-4}	10^{-3}	5×10^{-3}	10^{-2}	5×10^{-2}
no	60-40	96,7	97,5	96,5	94,0	36,1 (∞)
no	70-30	96,1	96,4	97,1	97,3	44,4 (∞)
no	80-20	97,4	97,4	96,4	92,3	34,3 (∞)
no	90-10	96,4	96,4	96,4	94,9	62,0 (∞)
sí	60-40	88,9	96,9	96,5	96,5	96,4
sí	70-30	90,8	96,1	96,1	96,1	95,9
sí	80-20	91,6	97,4	97,8	97,8	97,4
sí	90-10	93,4	96,4	96,4	96,4	96,4




Figura 6. Adaline en billetes. Exactitud en prueba contra α , sin escalar a la izquierda y con escalado a la derecha. Sin escalar, $\alpha = 0,05$ diverge.

que alcanza 17,9, ya que en la regla delta la corrección es proporcional a la entrada y una entrada de magnitud grande amplifica el paso efectivo [9]. Con las entradas escaladas al rango $[0, 1]$ cualquier valor de α entre 0,001 y 0,05 produce entre 95,9 y 97,8 %, y solo $\alpha = 10^{-4}$ resulta demasiado lento y se queda entre 88,9 y 93,4 % al agotar las 500 épocas. El escalado no eleva la exactitud máxima, que sin escalar también llega a 97,5 % con α pequeño, sino que hace al entrenamiento insensible al valor de α dentro de un rango amplio. La Fig. 6 muestra las dos situaciones. El mejor caso, la partición 80-20 escalada con $\alpha = 0,005$, llega a 97,8 % en prueba con 287 épocas. Sobre esa misma partición el perceptrón obtiene entre 97,4 y 98,9 % sin converger en ninguna ejecución, de modo que clasifica de forma ligeramente más precisa mientras el Adaline ofrece un criterio de terminación predecible.

V. CONCLUSIONES

Se implementaron el perceptrón simple y el Adaline como funciones de MATLAB completamente parametrizables y se evaluaron sobre compuertas lógicas y dos conjuntos de datos reales en cuatro proporciones de partición, cubriendo los doce puntos del taller.

El perceptrón con cualquiera de las tres reglas resuelve las compuertas AND y OR de 2, 3 y 4 entradas en menos de 20 épocas en promedio con $\alpha = 0,1$, siempre que la salida se codifique en $\{-1, 1\}$, ya que con la codificación $\{0, 1\}$ la primera regla queda inutilizada porque multiplicar por $d(x) = 0$ elimina la corrección. En Iris separa *setosa* con 100 % de exactitud y en billetes alcanza 99,3 % sin escalar las entradas,

aunque no converge en ninguna ejecución porque las clases no son perfectamente separables.

El Adaline resuelve las mismas compuertas entre 53 y 128 épocas usando la tolerancia de cambio del EC como criterio de parada, con 100 % de exactitud salvo en la AND de 4 entradas y en las OR de 3 y 4 entradas, donde la solución de mínimos cuadrados deja un patrón mal clasificado. Minimizar el error cuadrático de la salida lineal no equivale a minimizar el error de clasificación. En Iris iguala al perceptrón y en billetes alcanza 97,8 % con las entradas escaladas, mientras que sin escalar el error diverge para $\alpha = 0,05$ y la exactitud desciende al nivel del azar.

El factor de aprendizaje desempeña papeles opuestos en los dos modelos. En el perceptrón un valor alto no degrada el resultado y un valor bajo solo implica más épocas, mientras que en el Adaline existe un límite de estabilidad que depende de la magnitud de las entradas, y por esa razón el escalado, que no altera el resultado del perceptrón, es determinante para el Adaline. Entre las particiones 60-40 y 90-10 las diferencias de exactitud son de uno o dos puntos porcentuales y no siguen una dirección consistente, aunque las particiones con más datos de prueba producen estimaciones más estables. Ninguno de los dos modelos resuelve la XOR, en concordancia con la teoría.

Como limitaciones, los hiperparámetros no se ajustaron, los resultados en los conjuntos reales usan una sola semilla, de modo que diferencias menores a un punto porcentual no deberían interpretarse, y no se probó la normalización por puntuación z como alternativa al escalado min-max.

REFERENCIAS

- [1] F. Rosenblatt, "The perceptron: A probabilistic model for information storage and organization in the brain," *Psychological Review*, vol. 65, no. 6, pp. 386–408, 1958.
- [2] B. Widrow and M. E. Hoff, "Adaptive switching circuits," in *1960 IRE WESCON Convention Record, Part 4*, New York, 1960, pp. 96–104.
- [3] B. Widrow and M. A. Lehr, "30 years of adaptive neural networks: Perceptron, madaline, and backpropagation," *Proceedings of the IEEE*, vol. 78, no. 9, pp. 1415–1442, 1990.
- [4] S. Haykin, *Neural Networks and Learning Machines*, 3rd ed. Upper Saddle River, NJ: Pearson, 2009.
- [5] M. Minsky and S. Papert, *Perceptrons: An Introduction to Computational Geometry*. Cambridge, MA: MIT Press, 1969.
- [6] R. A. Fisher, "The use of multiple measurements in taxonomic problems," *Annals of Eugenics*, vol. 7, no. 2, pp. 179–188, 1936.
- [7] The MathWorks, Inc., "MATLAB version 26.1 (R2026a)," Natick, Massachusetts, 2026.
- [8] V. Lohweg, "Banknote authentication," UCI Machine Learning Repository, 2013, <https://doi.org/10.24432/C55P57>.
- [9] Y. LeCun, L. Bottou, G. B. Orr, and K.-R. Müller, "Efficient backprop," in *Neural Networks: Tricks of the Trade*, ser. Lecture Notes in Computer Science, G. B. Orr and K.-R. Müller, Eds. Berlin, Heidelberg: Springer, 1998, vol. 1524, pp. 9–50.
- [10] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York: Springer, 2006.