

Revision del dataset banknote paso a paso

Mismo esquema que con Iris: cada seccion deja una tabla en el workspace para Classification Learner, con Response = "clase".

```
clear; close all; clc
```

Paso 0: cargar y mirar el dato crudo

1372 billetes. A cada uno le tomaron una foto, le aplicaron una transformada wavelet y de ahí sacaron cuatro numeros que describen la textura. La clase dice si el billete es autentico (0) o falso (1).

```
datos = load('data_banknote_authentication.txt');
T = array2table(datos(:, 1:4), 'VariableNames', {'varianza', 'asimetria',
'curtosis', 'entropia'});
T.clase = categorical(datos(:, 5), [0 1], {'autentico', 'falso'});
vars = T.Properties.VariableNames(1:4);

T0_crudo = T;
disp(head(T0_crudo))
```

varianza	asimetria	curtosis	entropia	clase
3.6216	8.6661	-2.8073	-0.44699	autentico
4.5459	8.1674	-2.4586	-1.4621	autentico
3.866	-2.6383	1.9242	0.10645	autentico
3.4566	9.5228	-4.0112	-3.5944	autentico
0.32924	-4.4552	4.5718	-0.9888	autentico
4.3684	9.6718	-3.9606	-3.1625	autentico
3.5912	3.0129	0.72888	0.56421	autentico
2.0922	-6.81	8.4636	-0.60216	autentico

```
summary(T0_crudo)
```

T0_crudo: 1372x5 table

Variables:

```
varianza: double
asimetria: double
curtosis: double
entropia: double
clase: categorical (2 categories)
```


Statistics for applicable variables:

	NumMissing	Min	Median	Max	Mean	Std
varianza	0	-7.0421	0.4962	6.8248	0.4337	2.8428
asimetria	0	-13.7731	2.3197	12.9516	1.9224	5.8690
curtosis	0	-5.2861	0.6166	17.9274	1.3976	4.3100
entropia	0	-8.5482	-0.5867	2.4495	-1.1917	2.1010
clase	0					


```
% distribucion de cada variable por clase
```

```
figure('Position', [100 100 900 600]);
for k = 1:4
    subplot(2, 2, k); hold on
    for c = categories(T.clase)'
        histogram(T.(vars{k})(T.clase == c{1}), 25, 'DisplayName', c{1});
    end
    title(vars{k}); legend('Location', 'best');
end
sgtitle('Banknote crudo: histogramas por clase');
guardar_fig('rev_banknote_histogramas');
```


Banknote crudo: histogramas por clase



```
% boxplot: las cuatro estan en escalas distintas, la curtosis llega a 18
% y la entropia no pasa de 2.5
figure('Position', [100 100 700 400]);
boxplot(T{:, vars}, 'Labels', vars); grid on
title('Banknote crudo: cuatro escalas distintas');
guardar_fig('rev_banknote_boxplot_crudo');
```




```
% balance de la clase
figure('Position', [100 100 500 350]);
histogram(T.clase); ylabel('n'); title('Banknote: autenticos contra falsos'); grid
on
guardar_fig('rev_banknote_balance');
```



```
disp(table(categories(T.clase), countcats(T.clase), 'VariableNames', {'clase',
'n'}))
```

clase	n
{'autentico'}	762
{'falso' }	610

```
% dispersion de las dos mas informativas
figure('Position', [100 100 600 450]);
gscatter(T.varianza, T.asimetria, T.clase);
xlabel('varianza'); ylabel('asimetria'); grid on
title('Banknote: con varianza y asimetria casi se separan');
guardar_fig('rev_banknote_dispersion');
```



```
% Lo que se ve: 762 autenticos y 610 falsos, un desbalance suave. Las
% escalas son distintas entre variables, asi que estandarizar o
% normalizar deberia importar. La varianza sola ya separa bastante.
```

Paso 1: corregir outliers


Regla del 1.5*IQR recortando al borde.

```
T1_outliers = T0_crudo;
for k = 1:4
    x = T1_outliers.(vars{k});
    q = quantile(x, [0.25 0.75]);
    li = q(1) - 1.5*(q(2)-q(1));
    ls = q(2) + 1.5*(q(2)-q(1));
    fprintf('%-10s: %d valores fuera de [%.2f, %.2f]\n', vars{k}, sum(x<li | x>ls),
    li, ls);
    x(x < li) = li; x(x > ls) = ls;
    T1_outliers.(vars{k}) = x;
end
```

```
varianza : 0 valores fuera de [-8.67, 9.72]
asimetria : 0 valores fuera de [-14.50, 19.60]
```

curtosis : 57 valores fuera de [-8.75, 10.34]
entropia : 33 valores fuera de [-6.63, 4.61]


```
figure('Position', [100 100 700 400]);  
boxplot(T1_outliers{:, vars}, 'Labels', vars); grid on  
title('Banknote sin outliers');  
guardar_fig('rev_banknote_boxplot_outliers');
```



Paso 2: balancear las clases

Se toman al azar 610 autenticos para igualar a los 610 falsos.

```
rng(1)  
falsos = T1_outliers(T1_outliers.clase == 'falso', :);  
autenticos = T1_outliers(T1_outliers.clase == 'autentico', :);  
autenticos = autenticos(randperm(height(autenticos), height(falsos)), :);  
T2_balanceado = [autenticos; falsos];  
  
figure('Position', [100 100 500 350]);  
histogram(T2_balanceado.clase); ylabel('n'); title('Banknote balanceado'); grid on  
guardar_fig('rev_banknote_balance_despues');
```




```
fprintf('Antes: %d filas. Despues: %d filas (%d de cada clase).\n', ...
    height(T1_outliers), height(T2_balanceado), height(falsos));
```

Antes: 1372 filas. Despues: 1220 filas (610 de cada clase).

Paso 3: estandarizar (media 0, desviacion 1)


```
T3_estandarizado = T2_balanceado;
for k = 1:4
    T3_estandarizado.(vars{k}) = zscore(T2_balanceado.(vars{k}));
end
figure('Position', [100 100 700 400]);
boxplot(T3_estandarizado{:, vars}, 'Labels', vars); grid on
title('Banknote estandarizado: ahora si se comparan');
guardar_fig('rev_banknote_boxplot_estandarizado');
```



Paso 4: normalizar (entre 0 y 1)

Parte del balanceado, no del estandarizado.

```
T4_normalizado = T2_balanceado;
for k = 1:4
    x = T2_balanceado.(vars{k});
    T4_normalizado.(vars{k}) = (x - min(x)) / (max(x) - min(x));
end
figure('Position', [100 100 700 400]);
boxplot(T4_normalizado{:, vars}, 'Labels', vars); grid on
title('Banknote normalizado');
guardar_fig('rev_banknote_boxplot_normalizado');
```



Resumen

```
disp('Tablas listas para Classification Learner (Response = clase):')
```

Tablas listas para Classification Learner (Response = clase):

```
disp({'T0_crudo'; 'T1_outliers'; 'T2_balanceado'; 'T3_estandarizado';  
'T4_normalizado'})
```

```
{'T0_crudo'      }  
{'T1_outliers'  }  
{'T2_balanceado'}  
{'T3_estandarizado'}  
{'T4_normalizado' }
```